# Геометрия ландшафта потерь: структура спектра Гессиана, измерение остроты и механизмы оптимизации

## Геометрия ландшафта потерь: структура спектра Гессиана, измерение остроты и механизмы оптимизации

В современной теории глубокого обучения существует фундаментальный теоретический парадокс: почему сверхпараметризованные нейронные сети, содержащие от сотен миллионов до триллионов параметров, вообще способны эффективно обучаться с помощью базовых градиентных методов первого порядка? С точки зрения классической теории оптимизации, минимизация невыпуклой функции в пространствах сверхвысокой размерности относится к классу NP-трудных задач из-за обилия локальных субоптимальных минимумов, седловых точек и экстремальной кривизны.

Ответ на этот вопрос лежит в исследовании геометрической микроструктуры локальной кривизны ландшафта функции потерь, описываемой матрицей вторых производных — **матрицей Гессиана**. В отличие от произвольных многомерных невыпуклых функций, функции потерь глубоких нейросетей обладают строго выраженными алгебраическими и топологическими свойствами.

**Ключевая цель лекции:** Установить строгую математическую и концептуальную связь между микроструктурой кривизны ландшафта потерь (спектром Гессиана), поведением оптимизаторов первого порядка (SGD, Adam, SWA) и способностью модели обобщать выученные закономерности на новые данные (генерализацией).

**Основные темы рассмотрения:**

1. Локальная квадратичная аппроксимация, дифференциальная геометрия ландшафта и вычислительные методы анализа вторых производных.
2. Универсальный феномен спектрального расщепления Гессиана на массив околонулевых значений («Bulk») и изолированные выбросы («Outliers»).
3. Количественная оценка остроты минимумов, связь остроты с обобщением и парадоксы режима устойчивости («Edge of Stability»).
4. Геометрические причины превосходства адаптивных методов (Adam) над стохастическим градиентным спуском в сильно анизотропных ущельях.
5. Стохастическое усреднение весов (SWA) как метод регуляризации геометрии и центрирования параметров внутри нерегулярных бассейнов потерь.

---

## Локальная квадратичная модель ландшафта потерь

Для теоретического анализа динамики градиентного спуска в малой окрестности некоторой точки параметров $\theta \in \mathbb{R}^d$ гладкая функция потерь $L(\theta)$ раскладывается в ряд Тейлора второго порядка:

$$L(\theta + \Delta\theta) \approx L(\theta) + \nabla L(\theta)^T \Delta\theta + \frac{1}{2}\Delta\theta^T H(\theta)\Delta\theta$$

Главным объектом, определяющим локальную геометрию, является **матрица Гессиана** $H(\theta) \in \mathbb{R}^{d\times d}$, состоящая из вторых частных производных:

$$H_{ij} = \frac{\partial^2 L(\theta)}{\partial\theta_i \partial\theta_j}$$

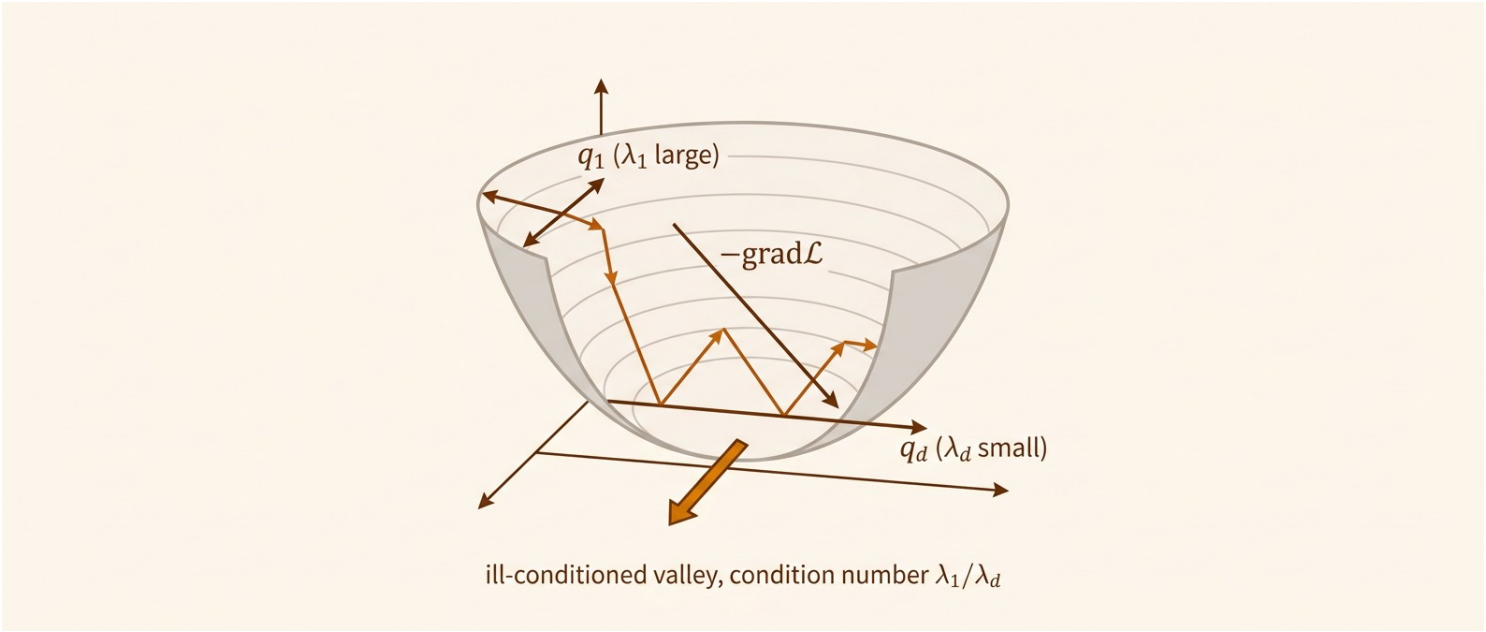



Рис. 1: Параболоид с осями главных кривизн

В силу теоремы Шварца о равенстве смешанных производных, Гессиан является вещественной симметричной матрицей ($H = H^T$). Следовательно, по спектральной теореме он допускает спектральное разложение по ортонормированному базису:

$$H = Q\Lambda Q^T = \sum_{i=1}^{d} \lambda_i q_i q_i^T$$

где:

- $\lambda_1 \geq \lambda_2 \geq \ldots \geq \lambda_d$ — вещественные собственные значения, определяющие величину и знак кривизны поверхности вдоль соответствующих осей.
- $q_i \in \mathbb{R}^d$ — взаимно ортогональные единичные собственные векторы ($q_i^T q_j = \delta_{ij}$), указывающие направления главных кривизн ландшафта.

**Классификация критических точек ($\nabla L(\theta^*) = 0$)**

Поведение оптимизатора в окрестности стационарных точек определяется исключительно спектром Гессиана:

1. **Локальный минимум:** Необходимое условие второго порядка требует неотрицательной определенности матрицы Гессиана: $H(\theta^*) \succeq 0$, то есть все собственные числа неотрицательны ($\forall i : \lambda_i \geq 0$). Достаточным условием строгого локального минимума является строгая положительная определенность: $H(\theta^*) \succ 0$ ($\forall i : \lambda_i > 0$).
2. **Седловая точка:** Спектр содержит как положительные, так и отрицательные значения ($\lambda_1 > 0 > \lambda_d$).
3. **Локальный максимум:** Все собственные значения строго отрицательны ($\lambda_i < 0$), что на практике обучения нейросетей встречается крайне редко из-за природы функции потерь.

Отношение $\kappa = \frac{\lambda_1}{\lambda_d}$ (или $\frac{\lambda_{\max}}{\lambda_{\min}}$ для строго положительного спектра) задает **число обусловленности** Гессиана. В геометрии функции потерь число обусловленности характеризует эксцентриситет эллип-

соидов изолиний. Если $\kappa \gg 1$, линии уровня представляют собой сверхузкие вытянутые овраги. Поскольку антиградиент $-\nabla L(\theta)$ всегда перпендикулярен касательной к изолинии, градиентный спуск направлен не на дно оврага, а бьет в противоположную стенку, вызывая катастрофические осцилляции.

---

## Вычислительный барьер: квадратичная память и кубическая сложность

Применение классических методов оптимизации второго порядка (таких как метод Ньютона $\theta_{t+1} = \theta_t - H^{-1}\nabla L$) сталкивается с фундаментальным вычислительным барьером, обусловленным размерностью пространства параметров $d$ современных нейросетей:

- **ResNet-50:** $d \approx 2.5 \times 10^7$ параметров.
- **LLaMA-3 (8B):** $d \approx 8.0 \times 10^9$ параметров.

### Ограничения по памяти

Плотная матрица $H$ содержит $d \times d$ элементов. Для хранения матрицы в стандартной точности `float32` (4 байта на число) требуется $4 \cdot d^2$ байт:

- Для **ResNet-50**:

$$(2.5 \times 10^7)^2 \times 4 \text{ байт} \approx 2.5 \times 10^{15} \text{ байт} = \textbf{2 500 ТБ} = \textbf{2.5 ПБ}$$

- Для **LLaMA-3 (8B)**:

$$(8.0 \times 10^9)^2 \times 4 \text{ байт} \approx 2.56 \times 10^{20} \text{ байт} = \textbf{256 Экзабайт}$$

*Для контекста: 256 экзабайт превосходит совокупный объем оперативной памяти всех вычислительных центров на планете Земля.*

### Временная сложность

Помимо невозможности материализации матрицы в памяти, стандартная процедура спектрального разложения (QR-алгоритм или приведение к симметричной трехдиагональной форме алгоритмом Хаусхолдера с последующим QR) требует $\mathcal{O}(d^3)$ арифметических операций с плавающей точкой (FLOPs). Для модели размером в миллиард параметров $d^3 \approx 10^{27}$ операций, что превышает время вычислений современных суперкомпьютеров на несколько десятилетий.

### Концептуальный переход: парадигма Hessian-Free

Прямое вычисление и хранение Гессиана физически невозможны. Поэтому анализ кривизны нейросетей базируется на парадигме **Hessian-Free (бесгессиановой оптимизации)**. В этом подходе Гессиан воспринимается не как массив чисел в памяти, а как **линейный оператор** $\mathcal{A} : \mathbb{R}^d \to \mathbb{R}^d$, задаваемый неявным правилом умножения матрицы на произвольный вектор:

$$v \mapsto Hv$$

---

## Hessian-Free подходы и трюк Перлмуттера (Pearlmutter Trick)

Произведение матрицы Гессиана на вектор $v \in \mathbb{R}^d$ (операция Hessian-Vector Product, HVP) представляет собой классическую направленную производную градиентного поля $\nabla L(\theta)$ вдоль направления $v$:

$$Hv = \nabla^2 L(\theta)v = \lim_{\epsilon \to 0} \frac{\nabla L(\theta + \epsilon v) - \nabla L(\theta)}{\epsilon} = \frac{\partial}{\partial \alpha} \nabla L(\theta + \alpha v)\Big|_{\alpha=0}$$

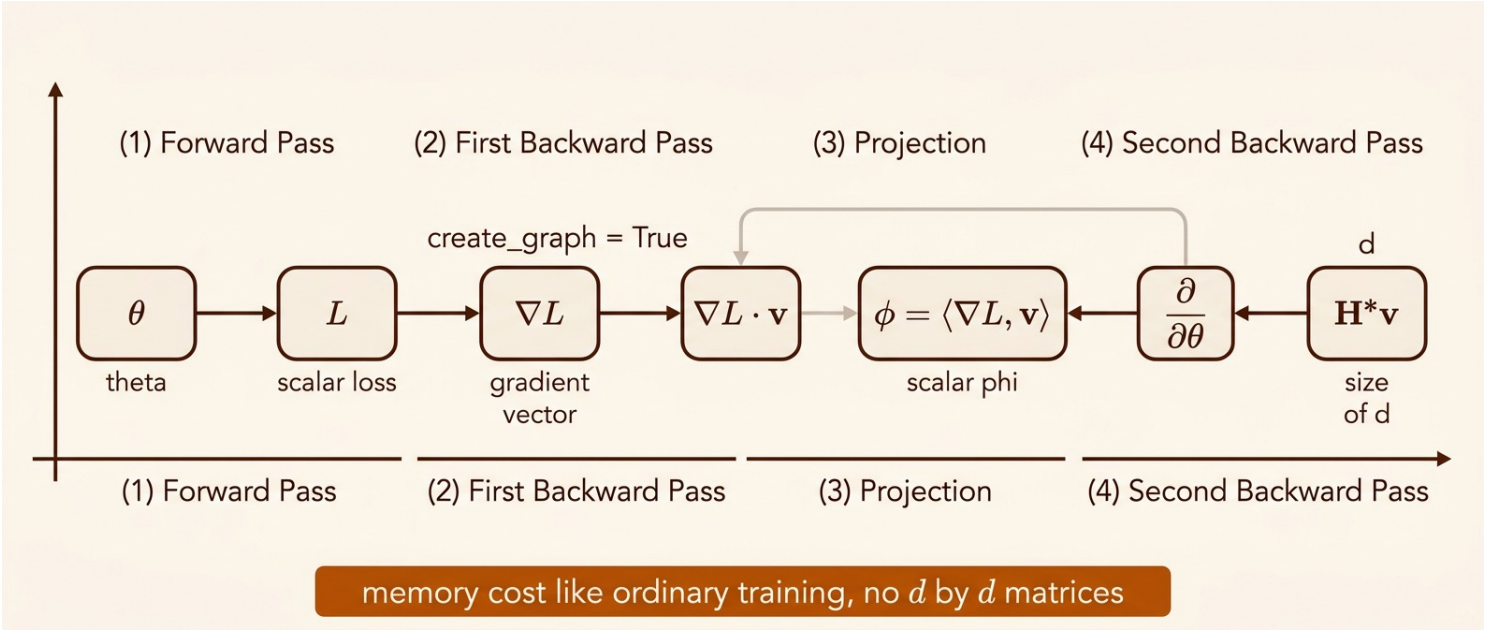



Рис. 2: Граф автодифференцирования, трюк Перлмуттера

В 1994 году Барак Перлмуттер сформулировал так называемый $\mathcal{R}$**-оператор**, позволивший вычислять HVP с машинной точностью через алгоритмы автоматического дифференцирования без использования приближенных конечно-разностных схем.

Математически вычисление сводится к композиции двух скалярных операций дифференцирования:

1. Вычисляется проекция градиента на вектор $v$, дающая скалярную функцию:

$$\phi(\theta) = \langle \nabla_\theta L(\theta), v \rangle$$

2. Градиент от полученного скаляра $\phi(\theta)$ по вектору параметров $\theta$ возвращает в точности $Hv$:

$$\nabla_\theta \phi(\theta) = \nabla_\theta \left( \sum_{i=1}^{d} \frac{\partial L}{\partial \theta_i} v_i \right) = \sum_{i=1}^{d} \nabla_\theta \left( \frac{\partial L}{\partial \theta_i} \right) v_i = \nabla^2 L(\theta)v = Hv$$

### Реализация в вычислительных графах (PyTorch)

В фреймворках современного глубокого обучения трюк Перлмуттера реализуется с помощью двойного обратного прохода (reverse-on-reverse дифференцирование):

```
import torch
```

```python
# Шаг 1: Вычисление градиента с сохранением графа
#        дифференцирования
# Параметр create_graph=True критически важен: он заставляет
# движок autograd построить граф вычислений для самого
# backward pass
loss = loss_fn(model(x), y)
grad_params = torch.autograd.grad(loss, model.parameters(),
                                  create_graph=True)

# Шаг 2: Вычисление проекции (скалярного произведения grad * v)
# и последующее дифференцирование по исходным параметрам
flat_grad = torch.cat([g.contiguous().view(-1)
                       for g in grad_params])
grad_v_prod = torch.dot(flat_grad, v)

# Вектор Hv получается дифференцированием скаляра grad_v_prod:
Hv = torch.autograd.grad(grad_v_prod, model.parameters(),
                         retain_graph=False)
```

**Вычислительная сложность HVP:**

- **По времени:** Применение трюка Перлмуттера требует одного прямого прохода и двух обратных проходов (Forward pass $\rightarrow$ Backward pass $\rightarrow$ Second Backward pass). Таким образом, время вычисления $Hv$ составляет константный множитель $\approx 2$–$3\times$ относительно стандартной итерации вычисления градиента. Временная сложность строго линейна по числу параметров: $\mathcal{O}(d)$.
- **По памяти:** Требуется хранение промежуточных узлов активаций первого backward-прохода, что сохраняет пространственную сложность на уровне $\mathcal{O}(\text{активации} + d)$. Память размера $\mathcal{O}(d^2)$ не задействуется вовсе.

---

## Численный спектральный анализ: метод Ланцоша и SLQ

Имея оператор неявного матрично-векторного произведения $v \mapsto Hv$, можно извлекать как экстремальные спектральные компоненты, так и полную плотность распределения собственных значений без материализации Гессиана.

### Итерации Ланцоша (Lanczos Algorithm)

Метод Ланцоша находит экстремальные собственные значения эрмитовых матриц большой размерности. Алгоритм строит ортонормированный базис подпространства Крылова размерности $m \ll d$:

$$\mathcal{K}_m(H, v_1) = \text{span}\{v_1, Hv_1, H^2v_1, \dots, H^{m-1}v_1\}$$

Базисные векторы $\{q_1, \dots, q_m\}$ генерируются по трехчленному рекуррентному соотношению (ортогонализация Грама-Шмидта, оптимизированная для симметричных матриц):

$$\beta_j q_{j+1} = Hq_j - \alpha_j q_j - \beta_{j-1} q_{j-1}$$

где коэффициенты проекции вычисляются как $\alpha_j = q_j^T H q_j$, а $\beta_j = \|Hq_j - \alpha_j q_j - \beta_{j-1} q_{j-1}\|_2$.

Проекция матрицы $H$ на подпространство Крылова $\mathcal{K}_m$ представляется вещественной симметричной **трехдиагональной матрицей** $T_m \in \mathbb{R}^{m \times m}$:

$$T_m = Q_m^T H Q_m = \begin{pmatrix} \alpha_1 & \beta_1 & 0 & \dots & 0 \\ \beta_1 & \alpha_2 & \beta_2 & \dots & 0 \\ 0 & \beta_2 & \alpha_3 & \ddots & \vdots \\ \vdots & \vdots & \ddots & \ddots & \beta_{m-1} \\ 0 & 0 & \dots & \beta_{m-1} & \alpha_m \end{pmatrix}$$

Собственные значения матрицы $T_m$ (так называемые **числа Ритца**) экспоненциально быстро сходятся к максимальным и минимальным собственным числам исходного Гессиана $\lambda_{\max}(H)$ и $\lambda_{\min}(H)$. Для практической сходимости границы спектра в сетях с миллиардами параметров достаточно всего $m \sim 20\text{–}100$ шагов HVP.

### Стохастическая квадратура Ланцоша (Stochastic Lanczos Quadrature, SLQ)

Если метод Ланцоша находит лишь крайние точки, то SLQ позволяет восстановить всю непрерывную спектральную плотность (Empirical Spectral Density, ESD):

$$\rho(\lambda) = \frac{1}{d} \sum_{i=1}^{d} \delta(\lambda - \lambda_i)$$

Алгоритм SLQ базируется на трех этапах:

1. **След матричной функции:** Интеграл от гладкой тестовой функции $f(\lambda)$ (например, ядра гауссова сглаживания) по спектральной плотности выражается через след матрицы:

$$\int f(\lambda)\rho(\lambda)d\lambda = \frac{1}{d}\sum_{i=1}^{d} f(\lambda_i) = \frac{1}{d}\mathrm{Tr}(f(H))$$

2. **Оценка следа методом Хатчинсона (Hutchinson's Trace Estimator):** След линейного оператора оценивается как математическое ожидание квадратичной формы по случайным изотропным векторам $v$:

$$\mathrm{Tr}(f(H)) \approx \frac{1}{N_v}\sum_{k=1}^{N_v} v_k^T f(H) v_k, \quad \text{где } v_k \sim \mathcal{N}(0, I_d) \text{ или } v_k \in \{-1, +1\}^d$$

3. **Квадратура Гаусса через трехдиагональную матрицу $T_m$:** Скалярное произведение $v_k^T f(H) v_k$ рассматривается как интеграл Римана-Стилтьеса. Процедура Ланцоша длины $m$ из вектора $v_k$ в точности генерирует узлы и веса квадратурной формулы Гаусса:

$$v_k^T f(H) v_k \approx \|v_k\|_2^2 \cdot e_1^T f(T_m^{(k)}) e_1 = \|v_k\|_2^2 \sum_{j=1}^{m} [\tau_j^{(k)}]_1^2 f(\theta_j^{(k)})$$

где $\theta_j^{(k)}$ — собственные значения матрицы $T_m^{(k)}$, а $[\tau_j^{(k)}]_1$ — первая компонента соответствующих нормированных собственных векторов.

В результате спектр миллиардомерного линейного оператора восстанавливается через собственное разложение набора крошечных матриц $T_m$ размера $m \times m$ ($m \approx 50$), что требует считанных минут на одном GPU.

---

## Эмпирический спектр Гессиана: феномен «Bulk + Outliers»

Применение алгоритма SLQ к реальным архитектурам нейронных сетей (от классических полносвязных сетей и сверточных ResNet до Vision Transformers и современных LLM) позволило обнаружить универсальную спектральную макроструктуру.

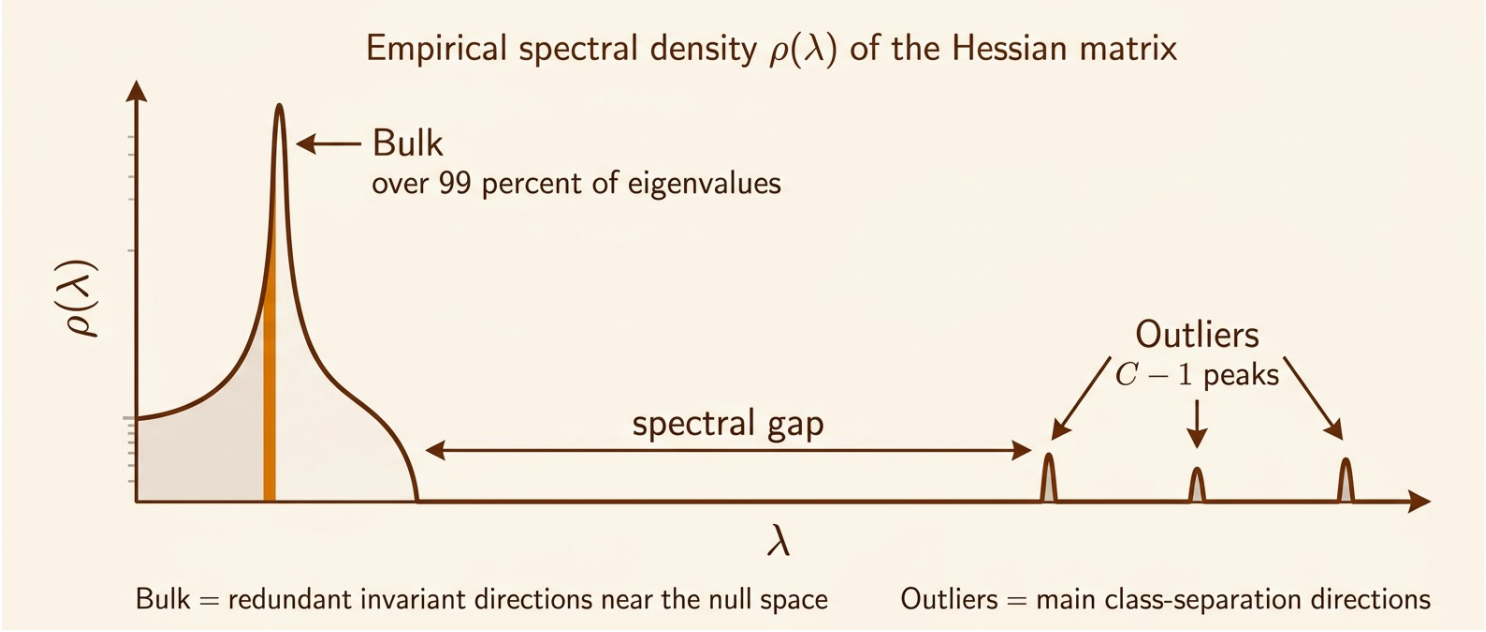



Рис. 3: Спектр Гессиана: Bulk и Outliers

Эмпирический спектр Гессиана глубоких моделей в конце обучения всегда распадается на две изолированные компоненты:

### 1. Непрерывный массив околонулевых значений («Bulk»)

Подавляющая масса спектральной плотности ($> 99\%$ всех собственных значений) сосредоточена в непосредственной близости от нуля в интервале $\lambda \in [-\epsilon, +\epsilon]$.

- Это свидетельствует о **локальной вырожденности кривизны** ландшафта потерь: из миллионов направлений в пространстве параметров практически все являются почти плоскими.
- С физической точки зрения это объясняет феномен сжимаемости моделей (прунинг): удаление параметров или смещение вдоль направлений из Bulk практически не влияет на величину ошибки.

### 2. Изолированные спектральные выбросы («Outliers»)

На правом краю спектра располагается небольшое фиксированное количество аномально больших дискретных собственных значений, отделенных от массива Bulk протяженной **спектральной щелью (spectral gap)**, где собственные числа полностью отсутствуют.

Именно эта горстка направлений определяет локальную жесткость ландшафта, формирует максимальную кривизну $\lambda_{\max}$ и накладывает фундаментальные ограничения на шаг обучения оптимизаторов.

---

## Анатомия Гессиана: расщепление на компоненту Гаусса-Ньютона и невязки

Чтобы вскрыть математический источник феномена «Bulk + Outliers», необходимо провести дифференциально-геометрическую декомпозицию функции эмпирического риска:

$$L(\theta) = \frac{1}{N} \sum_{i=1}^{N} \ell(f(x_i; \theta), y_i)$$

где $f(x_i; \theta) \in \mathbb{R}^C$ — вектор выходов нейросети (логиты) для $i$-го примера, $\ell : \mathbb{R}^C \times \mathcal{Y} \to \mathbb{R}$ — гладкая функция потерь (например, Cross-Entropy), $N$ — объем выборки.

Вычислим градиент по параметрам через многомерное правило дифференцирования сложной функции:

$$\nabla_\theta L(\theta) = \frac{1}{N} \sum_{i=1}^{N} J_i^T \nabla_f \ell(f(x_i; \theta), y_i)$$

где $J_i = \frac{\partial f(x_i;\theta)}{\partial \theta} \in \mathbb{R}^{C \times d}$ — матрица Якоби выходов сети по ее весам.

Дифференцируя выражение для градиента еще раз по $\theta$ и применяя правило Лейбница (производная произведения), получаем строгое расщепление Гессиана на две составляющие:

$$H = \nabla_\theta^2 L(\theta) = G + E$$

**1. Обобщенная матрица Гаусса-Ньютона (Generalized Gauss-Newton, GGN):**

$$G = \frac{1}{N} \sum_{i=1}^{N} J_i^T \left[ \nabla_f^2 \ell(f(x_i; \theta), y_i) \right] J_i$$

- Матрица $G$ учитывает только первые производные сети (Якобианы $J_i$) и кривизну самой функции потерь по выходам $\nabla_f^2 \ell$.
- Если внешняя функция потерь $\ell(f, y)$ выпукла по логитам (что верно для MSE и Cross-Entropy), то матрица $\nabla_f^2 \ell$ положительно полуопределена. Следовательно, $G$ **всегда гарантированно положительно полуопределена**: $G \succeq 0$.
- В вероятностной трактовке матрица $G$ эквивалентна теоретической информационной матрице Фишера (Fisher Information Matrix, FIM) модели.

**2. Матрица невязок / внутренней кривизны архитектуры ($E$):**

$$E = \frac{1}{N} \sum_{i=1}^{N} \sum_{c=1}^{C} \left[ \nabla_f \ell(f(x_i; \theta), y_i) \right]_c \cdot \nabla_\theta^2 f_c(x_i; \theta)$$

Матрица $E$ содержит вторые производные самой нейросетевой функции $\nabla_\theta^2 f_c$, отражая внутреннюю нелинейность архитектуры, взвешенную с коэффициентами ошибок предсказания (невязками) $\left[ \nabla_f \ell \right]_c$.

### Доминирование GGN в окрестности минимума

В процессе успешного обучения современных сверхпараметризованных сетей достигается режим интерполяции: сеть подгоняет обучающую выборку практически безошибочно. В этом случае вектор невязок $[\nabla_f \ell] \to 0$. Как следствие:

$$\|E\|_2 \ll \|G\|_2 \implies H \approx G$$

Спектральная структура истинного Гессиана $H$ в оптимизированных моделях практически на $100\%$ определяется алгебраической структурой матрицы Гаусса-Ньютона $G$.

---

## Механизм происхождения выбросов: декомпозиция Папяна

Ключевой теоретический вопрос: почему в спектре $G$ вообще возникают изолированные выбросы (Outliers), и сколько их?

В серии работ Вигена Папяна (Vigen Papyan, 2018–2020) было доказано, что для задачи классификации на $C$ классов количество изолированных выбросов Гессиана строго равно:

$$k_{\text{outliers}} = C - 1 \quad (\text{либо } C)$$

### Ранг матрицы кривизны по логитам

В случае мультиклассовой кросс-энтропии вектор предсказанных вероятностей задается функцией софтмакс: $p_c = \frac{e^{f_c}}{\sum_k e^{f_k}}$. Первая производная потерь по вектору логитов имеет вид:

$$\nabla_f \ell = p - y$$

где $y$ — one-hot вектор истинного класса. Вторая производная (Гессиан потерь по логитам) вычисляется как:

$$\nabla_f^2 \ell = \text{diag}(p) - pp^T$$

Поскольку сумма элементов вероятностного распределения тождественно равна единице ($\sum_{c=1}^{C} p_c = 1$), вектор из единиц $\mathbf{1} = (1, 1, \dots, 1)^T$ лежит в ядре этой матрицы:

$$\left(\text{diag}(p) - pp^T\right)\mathbf{1} = p - p(p^T\mathbf{1}) = p - p(1) = 0$$

Следовательно, ранг матрицы $\nabla_f^2 \ell$ размерности $C \times C$ строго равен $C - 1$.

### Декомпозиция матрицы Гаусса-Ньютона

Папян доказал, что матрица $G$ может быть разложена на две компоненты путем расщепления градиентов выходов сети на межклассовое среднее и внутриклассовый разброс:

$$G = G_{\text{cross}} + G_{\text{within}}$$

1. $G_{\text{cross}}$ **(Межклассовая кривизна):** Формируется исключительно средними векторами градиентов логитов по каждому из $C$ классов. Ранг матрицы $G_{\text{cross}}$ жестко ограничен количеством классов и **в точности равен** $C - 1$.
2. $G_{\text{within}}$ **(Внутриклассовая кривизна):** Представляет собой сумму ковариационных матриц разброса градиентов внутри каждого отдельного класса.

### Связь с явлением Neural Collapse

В работах Папяна, Хана и Донохо (Papyan, Han, Donoho, 2020) было открыто явление **нейронного коллапса (Neural Collapse)**: к завершению процесса обучения скрытые представления объектов одного класса стягиваются в одну точку в признаковом пространстве.

- Сжатие внутриклассовой дисперсии приводит к тому, что ковариации градиентов внутри классов стремятся к нулю. Соответственно, спектр матрицы $G_{\text{within}}$ оказывается плотно упакован в узком интервале около нуля, формируя **Bulk**.
- Напротив, $C$ центроидов классов формируют в пространстве признаков вершины правильного симплекса (Simplex Equiangular Tight Frame, ETF). Размерность подпространства, натянутого на эти центроиды, равна $C-1$. Именно эти $C-1$ направлений межклассовой сепарации обладают гигантской спектральной мощностью в матрице $G_{\text{cross}}$, порождая дискретные **Outliers**.

---

## Физический смысл направлений: «жёсткие» и «мягкие» оси

Структура «Bulk + Outliers» делит многомерное пространство параметров модели на два качественно различных подпространства:

| Характеристика | «Жёсткие» оси (Outliers, $k \leq C-1$) | «Мягкие» оси (Bulk, $k > C$) |
|---|---|---|
| **Кривизна ($\lambda_k$)** | Экстремально высокая ($\lambda_k \gg 0$) | Околонулевая ($\lambda_k \approx 0$) |
| **Чувствительность потерь** | Смещение $\Delta\theta$ вызывает квадратичный взрыв потерь | Смещение $\Delta\theta$ практически оставляет потери неизменными |
| **Геометрическая роль** | Разделение классов (межклассовая дискриминация) | Избыточная емкость сети, внутренние симметрии параметров |
| **Динамика оптимизации** | Сходятся мгновенно; требуют жесткого ограничения шага $\eta < \frac{2}{\lambda_{\text{max}}}$ | Дрейфуют под действием стохастического шума (диффузия) |
| **Размерность подпространства** | Сверхмалая ($C-1 \ll d$) | Колоссальная (почти все пространство: $\approx d$) |

### Геометрическая картина ландшафта

В результате расщепления спектра локальный минимум функции потерь глубокой сети — это не круглая чаша («параболоид»), а **сверхмногомерный вытянутый каньон (желоб)**:

- **Поперек каньона** (вдоль $C-1$ жестких осей) возвышаются отвесные вертикальные скалы. Шаг в этом направлении разрушает взаимную геометрию разделения классов, приводя к мгновенной деградации точности.
- **Вдоль каньона** (по миллионам мягких осей) простирается плоское дно. Параметры могут свободно перемещаться по дну каньона на значительные евклидовы расстояния без изменения выходных предсказаний модели.

Данная концепция восходит к физической теории **«Sloppy Models» (Джеймс Сетна)**: сложные нелинейные системы с огромным числом свободных степеней свободы универсально демонстрируют иерархию гиперчувствительных («stiff») и абсолютно нечувствительных («sloppy») параметров.

---

## Формализация остроты минимума (Sharpness)

Понятие «остроты» (sharpness) или «плоскостности» (flatness) локального минимума интуитивно связывается с шириной ямы функции потерь. В современной теории оптимизации используются три основных математических способа формализации этого понятия:

### 1. Спектральная норма Гессиана (наихудшая локальная кривизна)

$$\text{Sharpness}_\lambda = \lambda_{\max}(H) = \|H\|_2$$

Данная метрика определяет крутизну стенок функции потерь вдоль самого опасного направления (ведущего собственного вектора $q_1$). Она локальна и задает максимальный допустимый шаг градиентного спуска с точки зрения устойчивости динамической системы.

### 2. След матрицы Гессиана (интегральная кривизна)

$$\text{Tr}(H) = \sum_{i=1}^{d} \lambda_i = d \cdot \mathbb{E}_{v \sim \mathcal{S}^{d-1}}[v^T H v]$$

След Гессиана характеризует усредненную кривизну по всем возможным направлениям гиперсферы $\mathcal{S}^{d-1}$. Физически след отражает дивергенцию векторного поля градиента вокруг минимума ($\text{Tr}(H) = \text{div}(\nabla L)$).

### 3. Окрестностная острота ($\epsilon$-sharpness)

Классические производные второго порядка чувствительны к локальным высокочастотным осцилляциям. В работах Кескара (Keskar et al., 2016) и Форе (Foret et al., 2021) предложена нелокальная метрика возмущения в шаре фиксированного радиуса $\rho$:

$$\mathcal{S}_\rho(\theta^*) = \max_{\|\epsilon\|_2 \leq \rho} [L(\theta^* + \epsilon) - L(\theta^*)]$$

Если точка $\theta^*$ является точным минимумом ($\nabla L(\theta^*) = 0$), то разложение в ряд Тейлора при малом радиусе возмущения $\rho$ дает прямую связь между окрестностной остротой и максимальным собственным числом Гессиана:

$$\mathcal{S}_\rho(\theta^*) \approx \max_{\|\epsilon\|_2 \leq \rho} \left[\frac{1}{2}\epsilon^T H \epsilon\right] = \frac{1}{2}\rho^2 \lambda_{\max}(H)$$

---

## Дилемма «Плоские vs Острые минимумы» и обобщающая способность

Связь между кривизной локального оптимума и качеством работы модели на тестовых данных была впервые сформулирована Хохрайтером и Шмидхубером (Hochreiter & Schmidhuber, 1997) в терминах принципа минимальной длины описания (MDL).

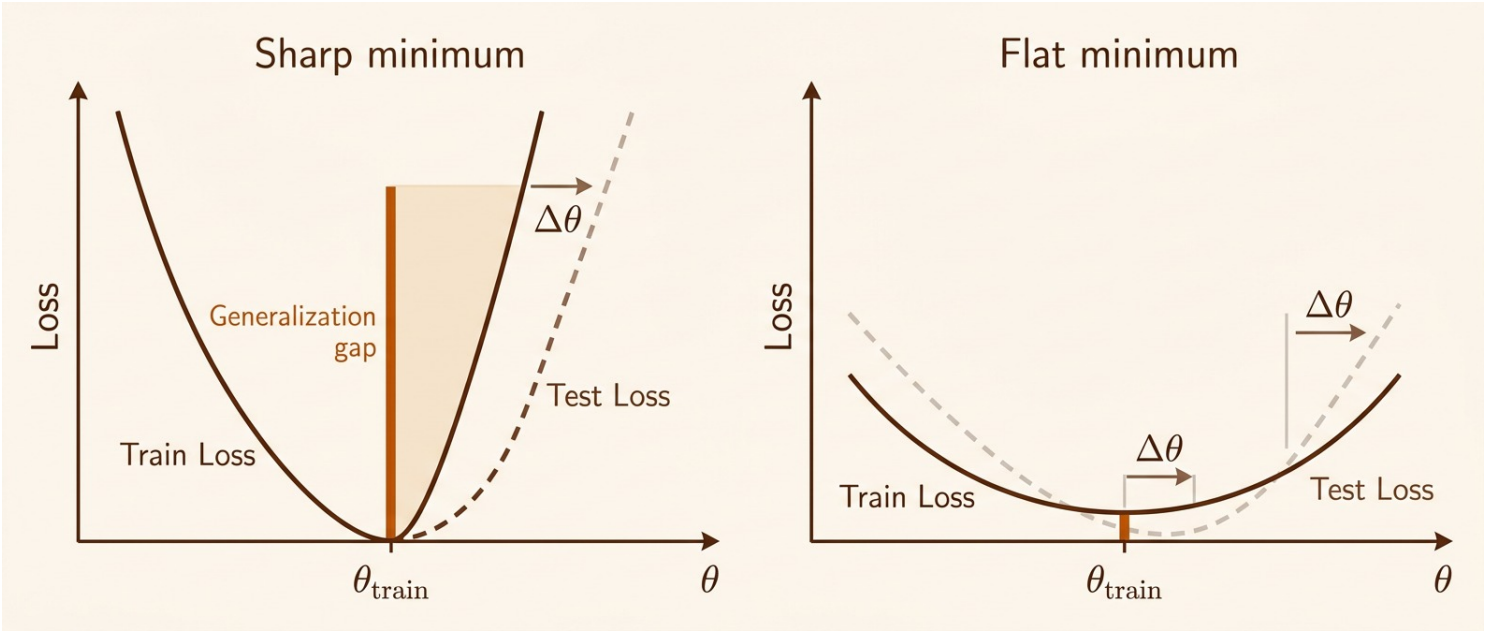



Рис. 4: Острые и плоские минимумы, разрыв обобщения

**Механизм смещения выборки (Sample Variance Shift)**

Обучение минимизирует эмпирический риск $L_{\text{train}}(\theta)$, построенный по выборке размера $N$. Истинный риск $L_{\text{test}}(\theta)$ вычисляется по генеральной совокупности данных распределения $\mathcal{D}$. В силу стохастической природы выборки конечного размера эмпирический ландшафт $L_{\text{train}}$ неизбежно сдвинут относительно идеального ландшафта $L_{\text{test}}$ на некоторый вектор возмущения:

$$\theta^*_{\text{test}} \approx \theta^*_{\text{train}} + \Delta\theta$$

Оценим величину дополнительной ошибки обобщения (Generalization Gap) через разложение в ряд Тейлора вокруг найденного минимума $\theta^*_{\text{train}}$:

$$L_{\text{test}}(\theta^*_{\text{train}}) - L_{\text{test}}(\theta^*_{\text{test}}) \approx \frac{1}{2}\Delta\theta^T H_{\text{test}}\Delta\theta \sim \frac{1}{2}\lambda_{\max}(H)\|\Delta\theta\|^2$$

- **В остром минимуме ($\lambda_{\max} \gg 1$):** Стенки функции потерь чрезвычайно крутые. Даже микроскопический шум выборки $\|\Delta\theta\|$ приводит к катастрофическому выбросу значения ошибки на тестовых данных.
- **В плоском минимуме ($\lambda_{\max} \ll 1$):** Дно долины пологое. Возмущение $\|\Delta\theta\|$ оставляет тестовую ошибку практически равной обучающей.

*Замечание о масштабировании (Dinh et al., 2017):* В сетях с функциями активации ReLU умножение весов одного слоя на $\alpha > 0$ и одновременное деление следующего слоя на $\alpha$ оставляет функцию сети абсолютно неизменной, но меняет Гессиан на коэффициент $\alpha^2$. Поэтому современный анализ остроты либо оперирует относительными метриками возмущения, либо рассматривает сети с механизмами нормализации (BatchNorm, LayerNorm), устраняющими произвол масштабной перепараметризации.

---

## Динамика обучения на грани устойчивости (Edge of Stability)

В классической численной оптимизации выпуклых квадратичных функций фундаментальная теорема сходимости гласит: градиентный спуск с фиксированным шагом (learning rate) $\eta$ устойчив и монотонно сходится к точке минимума тогда и только тогда, когда выполняется условие:

$$\eta < \frac{2}{\lambda_{\max}(H)}$$

При выходе за эту границу ($\eta > 2/\lambda_{\max}$) шаг по направлению ведущего собственного вектора $q_1$ приводит к росту ошибки: $|1 - \eta\lambda_{\max}| > 1$, вызывая экспоненциальную расходимость процесса (взрыв градиентов).

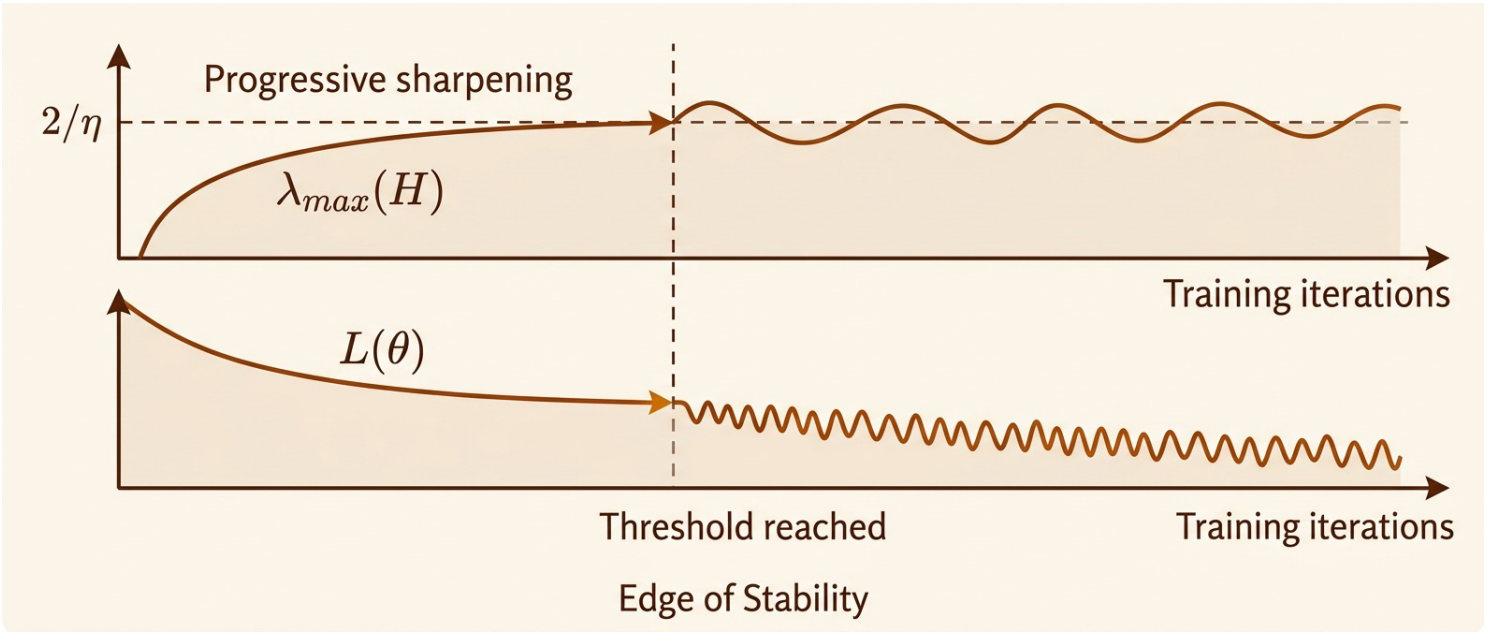



Рис. 5: Динамика на краю устойчивости (Edge of Stability)

### Открытие феномена EoS (Cohen et al., 2021)

Исследуя детерминированный градиентный спуск (Full-Batch GD) на глубоких сетях, Коэн и соавторы обнаружили, что нейросети систематически нарушают законы классической квадратичной теории, демонстрируя трехфазное поведение:

1. **Прогрессивное заострение (Progressive Sharpening):** На ранних этапах оптимизации максимальное собственное число Гессиана $\lambda_{\max}(H)$ монотонно и непрерывно возрастает, пока не достигнет критического порога:
$$\lambda_{\max}(H) \approx \frac{2}{\eta}$$
2. **Вход в режим «Edge of Stability»:** Вопреки классической теории, при достижении порога $2/\eta$ сеть **не расходится**.
3. **Нелинейная самостабилизация:** Оптимизатор входит в режим устойчивых нелинейных осцилляций. Величина $\lambda_{\max}(H)$ стабилизируется и колеблется чуть выше теоретического порога неустойчивости ($2/\eta$). При этом:

- На микроуровне функция потерь испытывает высокочастотные колебания вперед-назад вдоль направления $q_1$ на каждом шаге.
- На макроуровне (при усреднении по нескольким шагам) общая функция потерь продолжает стабильно снижаться.

**Механизм явления**

Эффект обусловлен нелинейными членами высших порядков функции потерь (порядка $\mathcal{O}(\|\Delta\theta\|^3)$ и $\mathcal{O}(\|\Delta\theta\|^4)$). Когда градиентный спуск выбрасывает параметры за пределы квадратичной зоны, кубические и четвертичные нелинейности «загибают» стенки оврага, ограничивая величину градиента и возвращая траекторию назад. Глубокое обучение в реальности протекает не в режиме идеальной квазистатической сходимости, а на динамической грани детерминированного хаоса.

---

## Патология SGD: сверхузкие овраги и число обусловленности

Рассмотрим локальную квадратичную модель функции потерь в окрестности оптимума $\theta^*$:

$$L(\theta) \approx L(\theta^*) + \frac{1}{2}(\theta - \theta^*)^T H (\theta - \theta^*)$$

Перейдем в ортонормированный базис собственных векторов Гессиана: $\tilde{\theta}_t = Q^T(\theta_t - \theta^*)$. В этом базисе матрица $H$ диагонализуется ($\Lambda = \text{diag}(\lambda_1, \dots, \lambda_d)$), и многомерный шаг градиентного спуска $\theta_{t+1} = \theta_t - \eta \nabla L(\theta_t)$ распадается на $d$ абсолютно независимых одномерных разностных уравнений:

$$\tilde{\theta}_{t+1}^{(k)} = (1 - \eta\lambda_k)\tilde{\theta}_t^{(k)}$$

Скорость сходимости по $k$-й координате полностью определяется мультипликативным фактором сжатия ошибки $\rho_k = |1 - \eta\lambda_k|$.

**Дилемма спектрального расщепления («Bulk + Outliers»)**

Спектр нейросети содержит две кардинально несопоставимые группы:

1. Изолированные выбросы ($\lambda_{\text{max}} = \lambda_{\text{outlier}}$).
2. Массив Bulk ($\lambda_{\text{bulk}} \approx 0$).

Число обусловленности такой системы катастрофически велико:

$$\kappa = \frac{\lambda_{\text{max}}}{\lambda_{\text{bulk}}} \gg 10^4\text{-}10^6$$

Чтобы оптимизатор не взорвался на крутых стенках, задаваемых жесткими осями, темп обучения $\eta$ обязан удовлетворять условию устойчивости:

$$\eta < \frac{2}{\lambda_{\text{max}}}$$

Выберем максимально допустимый для стабильности шаг: $\eta = \frac{2-\delta}{\lambda_{\text{max}}} \approx \frac{2}{\lambda_{\text{max}}}$. Подставим его в уравнение динамики для пологой координаты из массива Bulk:

$$\rho_{\text{bulk}} = 1 - \eta\lambda_{\text{bulk}} \approx 1 - \frac{2\lambda_{\text{bulk}}}{\lambda_{\text{max}}} = 1 - \frac{2}{\kappa}$$

### Катастрофический паралич сходимости

Чтобы уменьшить ошибку вдоль пологого направления в $e$ раз, требуется количество итераций $T$, определяемое из условия $\rho_{\text{bulk}}^T \approx e^{-1}$:

$$\left(1 - \frac{2}{\kappa}\right)^T \approx e^{-1} \implies T \approx \frac{\kappa}{2} = \mathcal{O}(\kappa)$$

Если число обусловленности $\kappa \sim 10^6$, обычному SGD требуется миллион итераций лишь для того, чтобы продвинуться на базовое расстояние вдоль дна ущелья. Траектория стохастического спуска вырождается в бесконечный зигзаг (zigzagging): градиент тратит всю энергию на осцилляции между противоположными крутыми склонами оврага, фактически замирая вдоль направления полезного движения.

---

## Архитектура Adam: адаптивное диагональное масштабирование

Алгоритм **Adam** (Adaptive Moment Estimation, Kingma & Ba, 2014) решает фундаментальную проблему анизотропии ландшафта за счет введения индивидуальной шкалы времени и индивидуального темпа обучения для каждого отдельного параметра.

### Математический аппарат алгоритма

На каждой итерации $t$ по батчу данных вычисляется стохастический градиент $g_t = \nabla_\theta L_B(\theta_t)$. Алгоритм обновляет две экспоненциальные скользящие средние:

1. **Первый момент (сглаженное направление движения / импульс):**

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t$$

*(по умолчанию $\beta_1 = 0.9$)*

2. **Второй нецентрированный момент (оценка мощности градиента по координатам):**

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2)(g_t \odot g_t)$$

*(по умолчанию $\beta_2 = 0.999$, где $\odot$ — покомпонентное умножение векторов, $g_t^2 = g_t \odot g_t$)*

### Коррекция смещения (Bias Correction)

Поскольку начальные значения моментов инициализируются нулями ($m_0 = 0, v_0 = 0$), на первых итерациях они сильно смещены в сторону нуля. Для устранения этого дефекта вычисляются скорректированные оценки:

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1 - \beta_2^t}$$

*Доказательство:* Развернем рекуррентную формулу $v_t$ полагая, что распределение градиентов стационарно ($\mathbb{E}[g_i^2] = \sigma^2$):

$$v_t = (1-\beta_2)\sum_{i=1}^{t}\beta_2^{t-i}g_i^2 \implies \mathbb{E}[v_t] = \sigma^2(1-\beta_2)\sum_{k=0}^{t-1}\beta_2^k = \sigma^2(1-\beta_2)\frac{1-\beta_2^t}{1-\beta_2} = \sigma^2(1-\beta_2^t)$$

Деление на $1-\beta_2^t$ гарантирует, что $\mathbb{E}[\hat{v}_t] = \sigma^2$, то есть оценка становится несмещенной с самого первого шага.

**Итоговое правило обновления параметров**

$$\theta_{t+1} = \theta_t - \eta\frac{\hat{m}_t}{\sqrt{\hat{v}_t}+\epsilon}$$

где деление и извлечение корня производятся строго поэлементно, а $\epsilon \approx 10^{-8}$ — константа вычислительной устойчивости.

---

## Геометрическая интерпретация: диагональное предобусловливание

С точки зрения геометрии оптимизации, идеальным алгоритмом второго порядка является **классический метод Ньютона**:

$$\theta_{t+1} = \theta_t - \eta H^{-1}\nabla L(\theta_t)$$

Предобусловливание градиента полной обратной матрицей Гессиана $H^{-1}$ полностью трансформирует метрику пространства. В трансформированном пространстве изолинии вытянутых эллипсоидов превращаются в идеальные концентрические сферы, и число обусловленности задачи становится равным единице:

$$\kappa(H^{-1}H) = \kappa(I) = 1$$

В такой системе сходимость на квадратичной функции достигается ровно за один шаг.

**Adam как приближенный предобусловливатель Якоби**

Так как хранить и обращать полную матрицу $H$ невозможно, Adam реализует ее диагональную аппроксимацию:

1. Покомпонентный квадрат стохастического градиента $g_t^2$ в математическом ожидании аппроксимирует диагональ матрицы Гаусса-Ньютона (и диагональ истинного Гессиана):

$$\mathbb{E}[(g_t)_i^2] \approx \text{diag}(G)_{ii} \approx \text{diag}(H)_{ii}$$

2. Деление на $\sqrt{\hat{v}_t}$ эквивалентно умножению вектора импульса на диагональную матрицу предобусловливателя $P_t$:

$$P_t = \text{diag}\left(\frac{1}{\sqrt{\hat{v}_t}+\epsilon}\right) \approx \text{diag}(H)^{-1/2}$$

### Геометрия преобразования координат

Действие оптимизатора эквивалентно переходу к новым масштабированным координатам:

$$\tilde{\theta} = \text{diag}(H)^{1/2}\theta$$

- По направлениям с гигантской кривизной (где $\text{diag}(H)_{ii} \gg 1$) компонента $v_t$ велика, и деление на $\sqrt{v_t}$ автоматически гасит скорость движения, предотвращая осцилляции и взрыв оптимизатора.
- По направлениям с крошечной кривизной (где $\text{diag}(H)_{ii} \ll 1$) компонента $v_t$ мала, и деление на $\sqrt{v_t}$ колоссально усиливает эффективный шаг, заставляя модель двигаться вдоль плоского дна каньона с высокой эффективной скоростью.

Ограничение метода заключается в том, что диагональная матрица не способна поворачивать оси координат. Если вытянутый овраг ориентирован под углом $45^\circ$ к базисным осям параметров, диагональное масштабирование не сможет полностью убрать недиагональную ковариацию. Однако на практике в глубоких сетях львиная доля дисбаланса масштабов связана именно с межслоевыми и межканальными различиями величины весов, которые диагональный предобусловливатель нивелирует.

---

## Геометрическая интерпретация: доказательство

Связь между квадратом первой производной $(\nabla L)^2$ и второй производной $\nabla^2 L$ базируется на теории оценивания и вероятностных моделях. Большинство функций потерь в машинном обучении сводятся к минимизации **отрицательного логарифмического правдоподобия (Negative Log-Likelihood, NLL)**:

$$L(\theta) = -\log p(y \mid x, \theta)$$

(Для классификации это Cross-Entropy, для регрессии с предположением о нормальном шуме — MSE).

### Второе тождество Бартлетта для матрицы Фишера

Пусть $p(y \mid \theta)$ — параметрическое распределение вероятностей. Условие нормировки плотности вероятности:

$$\int p(y \mid \theta)\, dy = 1$$

Продифференцируем обе части тождества по параметру $\theta$:

$$\nabla_\theta \int p(y \mid \theta)\, dy = \int \nabla_\theta p(y \mid \theta)\, dy = 0$$

Используя логарифмический трюк $\nabla_\theta p(y \mid \theta) = p(y \mid \theta)\nabla_\theta \log p(y \mid \theta)$, получаем первое тождество:

$$\int p(y \mid \theta)\nabla_\theta \log p(y \mid \theta)\, dy = \mathbb{E}_{y\sim p_\theta}\left[\nabla_\theta \log p(y \mid \theta)\right] = 0$$

Продифференцируем это выражение по $\theta$ второй раз:

$$\nabla_\theta \int p(y \mid \theta)\nabla_\theta \log p(y \mid \theta)^T\, dy = 0$$

Раскрывая производную произведения под интегралом:

$$\int \left(\nabla_\theta p(y \mid \theta) \nabla_\theta \log p(y \mid \theta)^T + p(y \mid \theta) \nabla_\theta^2 \log p(y \mid \theta)\right) dy = 0$$

Снова подставляя $\nabla_\theta p = p \nabla_\theta \log p$:

$$\int p(y \mid \theta) \left(\nabla_\theta \log p(y \mid \theta) \nabla_\theta \log p(y \mid \theta)^T\right) dy + \int p(y \mid \theta) \nabla_\theta^2 \log p(y \mid \theta)\, dy = 0$$

Переходя к математическим ожиданиям:

$$\mathbb{E}_{y \sim p_\theta}\left[\nabla^2(-\log p(y \mid \theta))\right] = \mathbb{E}_{y \sim p_\theta}\left[\nabla(-\log p(y \mid \theta)) \nabla(-\log p(y \mid \theta))^T\right]$$

- Левая часть формулы — это **математическое ожидание Гессиана** $\mathbb{E}[H]$.
- Правая часть — это **ковариационная матрица градиентов** (информационная матрица Фишера $F$).

Диагональные элементы матрицы Фишера в точности равны дисперсии компонент градиента:

$$F_{ii} = \mathbb{E}\left[\left(\frac{\partial L}{\partial \theta_i}\right)^2\right]$$

Таким образом, накопление квадратов градиентов $v_t \approx \mathbb{E}[g_i^2]$ в Adam — это статистическая оценка диагонали матрицы Фишера, которая, в силу тождества Бартлетта, равна математическому ожиданию диагонали Гессиана: $\mathbb{E}[v_t]_{ii} \approx \mathbb{E}[H_{ii}]$.

#### Почему деление на $\sqrt{v_t}$, а не на $v_t$?

В идеальном методе Ньютона вектор градиента умножается на обратный Гессиан первой степени: $H^{-1}$. Почему же Adam использует деление на $\sqrt{v_t}$, то есть $H^{-1/2}$?

1. **Практическая устойчивость:** Если модель попадает на пологое плато, где истинная кривизна $H_{ii} \to 0$, деление на $v_t \sim 0$ привело бы к колоссальному скачку шага в бесконечность ($\Delta\theta \sim 1/v_t$). Деление на корень $\sqrt{v_t}$ делает величину шага ограниченной сверху: при $\hat{m}_t \approx g_t$ шаг равен $\frac{g_t}{\sqrt{g_t^2}} = \text{sign}(g_t)$, превращая Adam на плато в устойчивый координатный метод знакового градиентного спуска (SignSGD).
2. **Изометрия метрики:** Растяжение пространства $\tilde{\theta} = H^{1/2}\theta$ нормирует производные первого порядка вдоль разных координат к единичной дисперсии.

---

## Спектральная трансформация: как Adam выравнивает динамику

На рисунке представлена фазовая плоскость двухпараметрической функции потерь с высоким числом обусловленности: изолинии представляют собой вытянутые эллипсы вдоль одной из координатных осей.

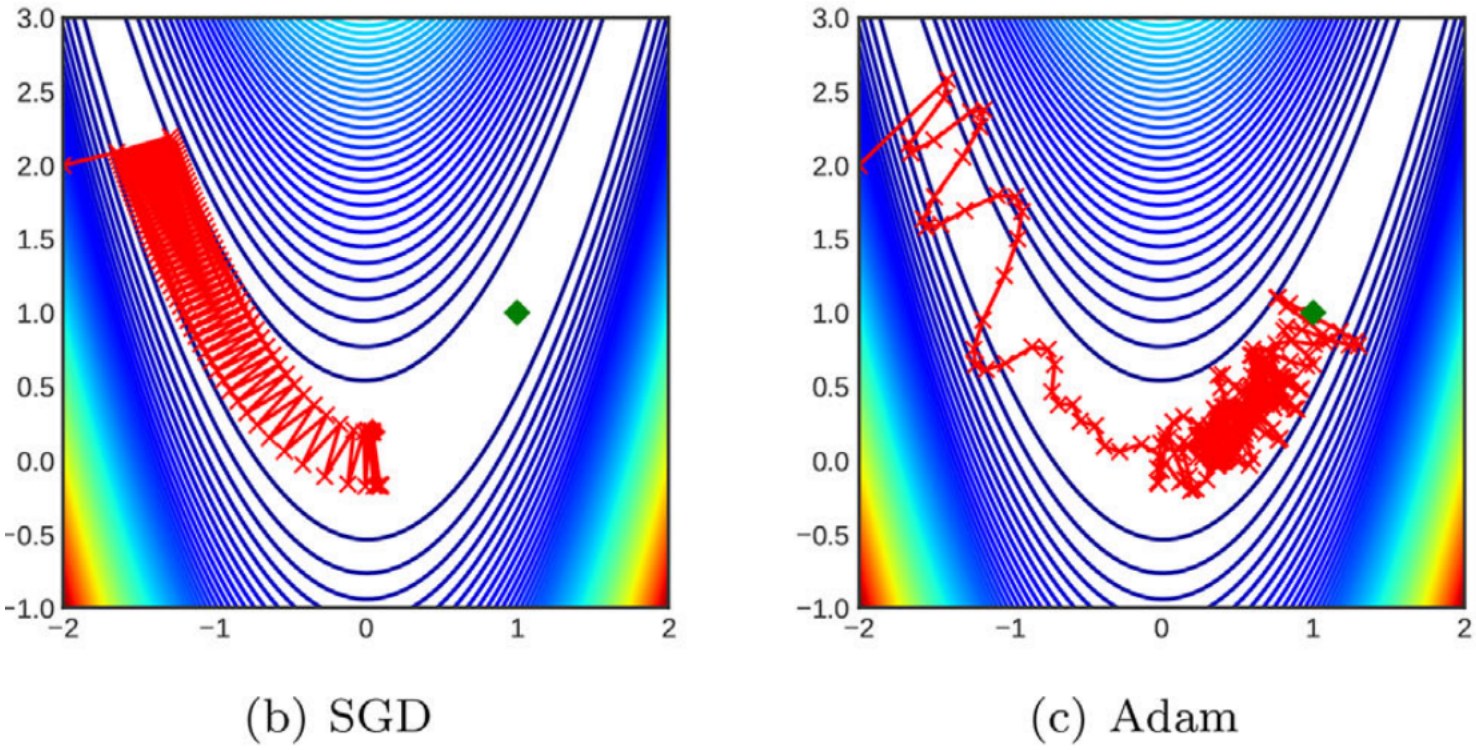



Рис. 6: Зигзаг SGD против траектории Adam на линиях уровня

**Поведение SGD:**

- Траектория стохастического градиентного спуска (красная траектория) испытывает характерный резонанс между стенками оврага. Поскольку вектор антиградиента ортогонален вытянутым изолиниям, его главная составляющая направлена по нормали к крутому склону, а не вдоль русла минимизации.
- SGD непрерывно «перелетает» через дно ущелья, совершая затухающие колебания высокой амплитуды. Продвижение к точке оптимума вдоль пологой оси происходит крайне медленно.

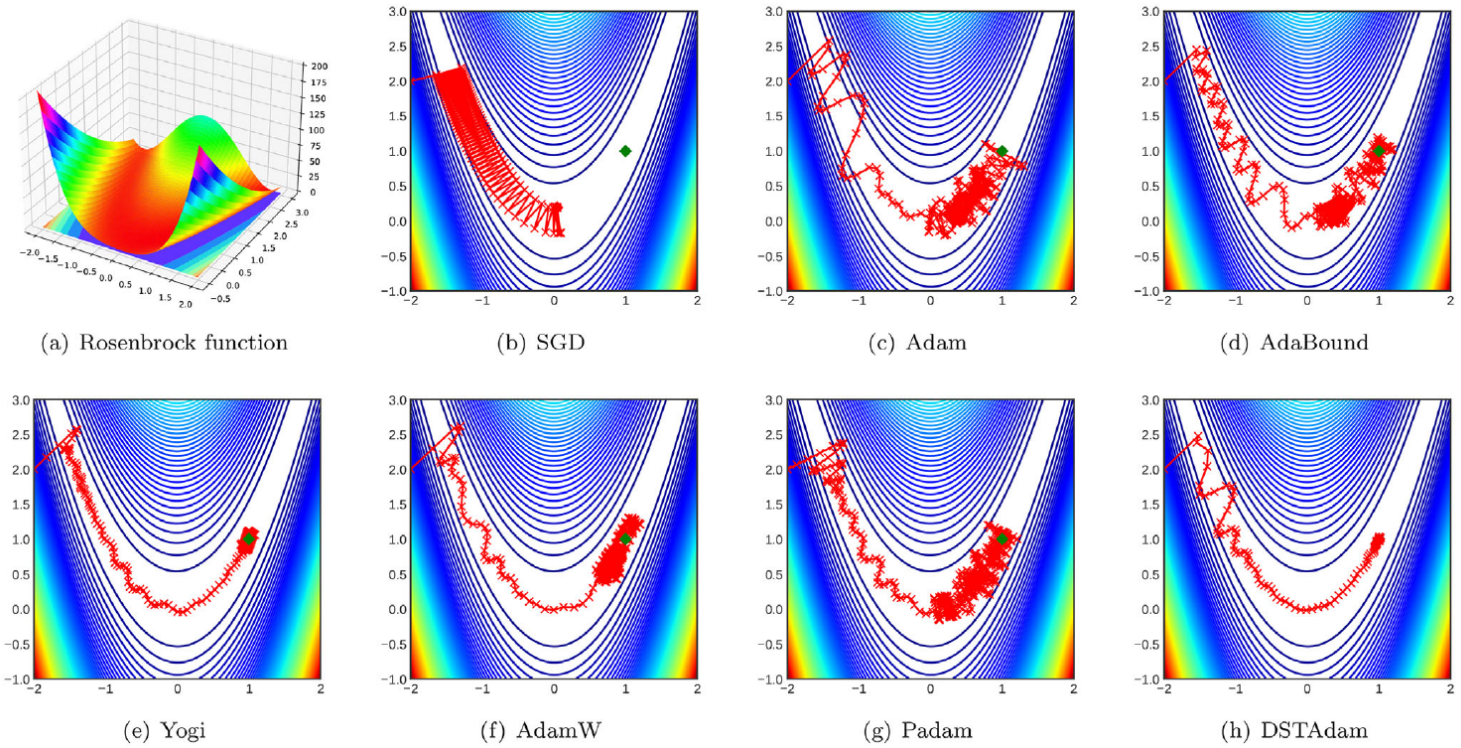
**Поведение Adam:**

- За счет накопления больших значений $v_t$ по вертикальной координате (высокая кривизна) эффективный темп обучения вдоль этой оси динамически занижается: $\eta_{\text{eff}} \ll \eta$.
- По горизонтальной оси (низкая кривизна) значения $v_t$ малы, что сохраняет или увеличивает эффективный шаг: $\eta_{\text{eff}} \approx \eta/\epsilon$.
- В результате траектория Adam (зеленая траектория) плавно сглаживает поперечные осцилляции и направляется практически по прямой линии точно в локальный минимум. Адаптивное предобусловливание эффективно преобразует эллиптический рельеф в изотропную сферическую чашу.

---

## Другие оптимизаторы

Развитие методов оптимизации в глубоком обучении представляет собой эволюцию компромиссов между скоростью сходимости адаптивных алгоритмов и качеством генерализации классического стохастического градиентного спуска.



(a) Rosenbrock function (b) SGD (c) Adam (d) AdaBound

(e) Yogi (f) AdamW (g) Padam (h) DSTAdam

Рис. 7: Сравнение оптимизаторов (Zeng et al., 2022)

**Основные ветви алгоритмов:**

1. **SGD с импульсом (Polyak Momentum / Nesterov Accelerated Gradient):** Решают проблему оврагов за счет усреднения векторов скорости во времени. Импульс гасит высокочастотные осцилляции поперек оврага и накапливает кинетическую энергию вдоль дна. Однако SGD с моментом по-прежнему использует один глобальный скалярный темп обучения для всех миллиардов параметров.
2. **AdaGrad (Duchi et al., 2011):** Исторически первый метод адаптивного масштабирования. Накапливает монотонно растущую сумму квадратов градиентов $G_t = \sum_{\tau=1}^{t} g_\tau^2$. Критический недостаток: знаменатель монотонно растет, что приводит к преждевременной остановке обучения еще до приближения к оптимуму.
3. **RMSprop (Hinton, 2012):** Модифицировал AdaGrad, заменив простую сумму на экспоненциально взвешенное скользящее среднее (EMA), что позволило алгоритму забывать далекую историю градиентов и адаптироваться к текущей локальной кривизне.
4. **AdamW (Loshchilov & Hutter, 2017):** Исправил фундаментальный дефект оригинального Adam при совместном использовании с $L_2$-регуляризацией (Weight Decay). В Adam $L_2$-штраф добавлялся к градиенту ($g_t \leftarrow g_t + \lambda\theta$), из-за чего веса с большими историческими градиентами штрафовались слабее, чем веса с редкими градиентами. AdamW реализует истинный Weight Decay, вычитая регуляризационный член напрямую из весов: $\theta_{t+1} = \theta_t(1 - \eta\lambda) - \eta\frac{\hat{m}_t}{\sqrt{\hat{v}_t}+\epsilon}$.
5. **Гибридные схемы (SWATS, Decreasing Scaling Schemes):** Адаптивные методы быстро находят хорошую область на ранних этапах, но иногда уступают SGD по тестовой точности на финише обучения. Методы класса SWATS (Switching from Adam to SGD) и схемы затухающего масштабирования (Zeng et al., 2022) автоматически переключают оптимизатор с адаптивного режима Adam на SGD в финальной фазе обучения, объединяя высокую скорость сходимости с устойчивой генерализацией.

---

## Реальная топология минимумов: асимметричные ущелья

Классическая квадратичная модель ландшафта (симметричный параболоид) дает локальное понимание динамики, но терпит крах при попытке описать глобальную топологию функции потерь современных сетей.

### 1. Асимметрия крутизны поперечного сечения

В реальных нейросетях бассейны притяжения никогда не бывают симметричными. Поперечный срез типичной долины потерь демонстрирует резкую асимметрию: с одной стороны находится крутой, практически вертикальный обрыв (образуемый функциями активации ReLU или операциями маскирования), а с противоположной стороны — пологое, плавно переходящее в плато пространство.

### 2. Связность минимумов (Mode Connectivity)

Одной из важнейших концепций геометрии глубокого обучения стало открытие **связности мод (Garipov et al., 2018; Draxler et al., 2018)**:

- Если инициализировать одну и ту же архитектуру из двух разных случайных точек и обучить стандартным SGD до сходимости в две разные точки $\theta_A^*$ и $\theta_B^*$, то прямолинейный отрезок между ними $\theta(\alpha) = (1-\alpha)\theta_A^* + \alpha\theta_B^*$ проходит через область с огромным барьером функции потерь.
- Однако в пространстве параметров всегда существует **непрерывная криволинейная траектория** $\phi(t)$, соединяющая $\theta_A^*$ и $\theta_B^*$, вдоль которой функция потерь остается практически постоянной и равной значению в минимумах:

$$\forall t \in [0,1]: \quad L(\phi(t)) \approx L(\theta_A^*) \approx L(\theta_B^*)$$

- Локальные минимумы в глубоких сетях не являются изолированными воронками. Они представляют собой единую связанную разветвленную сеть гиперповерхностей нулевого уровня потерь.

### 3. Геометрия сублевел-множеств

Сублевел-множества $\{\theta \mid L(\theta) \leq \epsilon\}$ представляют собой извилистые искривленные каньоны колоссальной протяженности. Дно этих каньонов не является прямой линией; оно изгибается в соответствии со сложными нелинейностями сетевых отображений, обладая миллионами направлений с квазинулевой кривизной.

---

## Почему стохастический градиентный спуск застревает на краях долин?

Экспериментальный анализ показывает парадоксальный факт: если оптимизировать модель с помощью SGD или Adam до полной остановки сходимости, финальная точка параметров почти всегда оказывается не на дне и не в геометрическом центре долины, а **на ее крутом внешнем склоне**, в области со сравнительно высокой кривизной $\lambda_{\text{max}}(H)$.

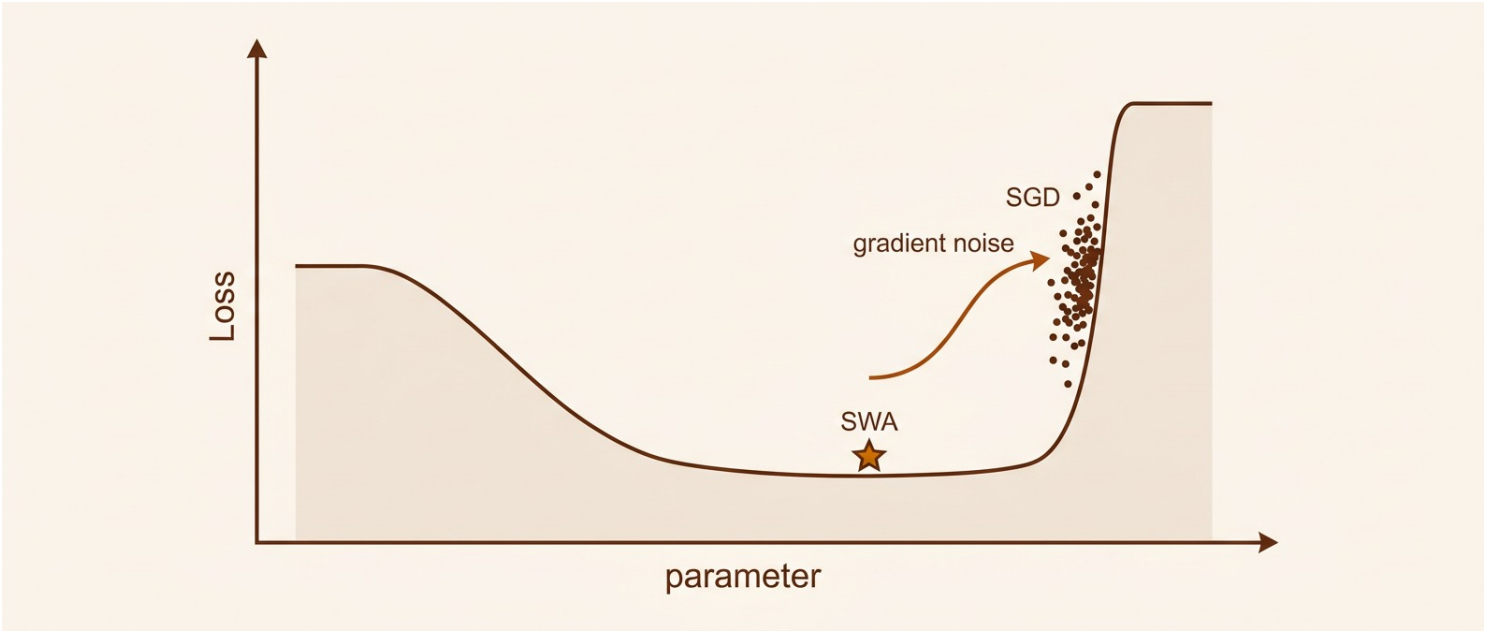



Рис. 8: SGD у крутой стены оврага, звезда SWA в центре

**Природа стохастического шума**

В стохастической оптимизации градиент оценивается по мини-батчу данных:

$$g_t(\theta) = \nabla L(\theta) + \xi_t$$

В приближении стохастических дифференциальных уравнений (СДУ Ито / уравнение Ланжевена) градиентный шум аппроксимируется гауссовым распределением: $\xi_t \sim \mathcal{N}(0, \Sigma(\theta))$. Ковариационная матрица шума $\Sigma(\theta)$ строго анизотропна: шум имеет максимальную дисперсию вдоль тех же жестких собственных направлений, которые доминируют в матрице Гаусса-Ньютона.

**Феномен энтропийного выталкивания (Entropic Force)**

В пространствах сверхвысокой размерности ($d \sim 10^7 - 10^{11}$) вступает в силу фундаментальное проклятие размерности, описываемое геометрической теорией меры: **подавляющая часть объема любого $d$-мерного тела сосредоточена в бесконечно тонком приповерхностном слое у его границы**.

- Отношение объема внутренней сферы радиуса $(1-\epsilon)R$ к объему полной сферы радиуса $R$ стремится к нулю экспоненциально:

$$\frac{\text{Vol}(B^d((1-\epsilon)R))}{\text{Vol}(B^d(R))} = (1-\epsilon)^d \xrightarrow[d\to\infty]{} 0$$

- Внутренняя область (центр долины) обладает исчезающе малым фазовым объемом по сравнению с огромным объемом периферийных областей у стенок оврага.
- Стохастический шум градиента вместе с конечным шагом обучения $\eta$ выступает в роли эффективной термодинамической температуры системы $T_{\text{eff}} \sim \frac{\eta}{B}\Sigma$. Эта тепловая флуктуация генерирует чисто статистическую **энтропийную силу**, которая неизбежно выталкивает блуждающую траекторию SGD из геометрического центра долины наружу, прижимая ее к крутым склонам периферии.

В результате SGD стабилизируется в точке равновесия между потенциальной силой градиента, тянущей вниз, и энтропийной силой шума, толкающей наружу. Полученное решение обладает высокой локальной кривизной $\lambda_{\max}$, что делает его уязвимым к сдвигу распределения тестовых данных.

---

## Алгоритм Stochastic Weight Averaging (SWA)

Метод **стохастического усреднения весов (Stochastic Weight Averaging, SWA)**, предложенный Измайловым, Подио-Гуидолини, Вагнером, Уилсоном и Менцелем (Izmailov et al., 2018), устраняет патологию энтропийного выталкивания за счет усреднения траектории движения параметров.

### Процедура алгоритма:

1. **Фаза стандартного спуска (Warmup):** Модель обучается стандартным оптимизатором (SGD или Adam) с монотонно убывающим расписанием темпа обучения (Cosine Annealing или Step Decay) в течение $75\%$ общего времени обучения, пока не достигнет дна широкого бассейна потерь.
2. **Фаза исследования долины (Exploration):** Оптимизатор переключается на постоянный умеренно высокий или циклический темп обучения $\eta(t)$ (Cyclic Learning Rate). Высокий темп обучения не позволяет весам «застрять» в случайной точке на границе и заставляет модель циклически обходить бассейн притяжения по его периферии.
3. **Сбор контрольных точек:** В моменты минимального темпа обучения каждого цикла (или через каждые $K$ итераций при постоянном LR) текущие веса модели $\theta_i$ сохраняются.
4. **Усреднение параметров:** Итоговая точка весов формируется как невзвешенное арифметическое среднее всех сохраненных промежуточных чекпоинтов:

$$\theta_{\text{SWA}} = \frac{1}{K}\sum_{k=1}^{K}\theta_k$$

   На практике усреднение ведется накопительным итеративным способом, не требующим хранения всех весов в памяти:

$$\theta_{\text{SWA}}^{(k)} = \frac{(k-1)\theta_{\text{SWA}}^{(k-1)} + \theta_k}{k}$$

### Критический шаг: финализация статистик Batch Normalization

Слои батч-нормализации содержат накопительные статистики: среднее значение активаций $\mu$ и дисперсию $\sigma^2$. Поскольку выход промежуточных слоев нейросети **нелинейно** зависит от параметров весов $\theta$ (в силу суперпозиции функций активаций):

$$\mathbb{E}_x[f(x;\theta_{\text{SWA}})] \neq \frac{1}{K}\sum_{k=1}^{K}\mathbb{E}_x[f(x;\theta_k)]$$

Простое усреднение статистик BN приводит к полной неработоспособности модели.

Поэтому после вычисления $\theta_{\text{SWA}}$ необходимо заморозить веса сети и выполнить **один полный проход по обучающему датасету без вычисления градиентов** (Forward pass only). Во время этого прохода слои BatchNorm вычисляют корректные средние и дисперсии для новой усредненной точки весов $\theta_{\text{SWA}}$.

*Принципиальное отличие SWA от ансамблирования (Ensemble):*

- **Классический ансамбль** усредняет выходы разных сетей в пространстве предсказаний: $\hat{y} = \frac{1}{K}\sum f(x;\theta_k)$. Это требует хранения $K$ моделей и увеличивает вычислительную сложность инференса ровно в $K$ раз.
- **SWA** усредняет веса внутри одного бассейна притяжения: $\hat{y} = f(x;\theta_{\text{SWA}})$. Вычислительная сложность и объем памяти на этапе инференса **в точности равны одной стандартной модели**.

---

## Геометрический эффект SWA: центрирование в долине

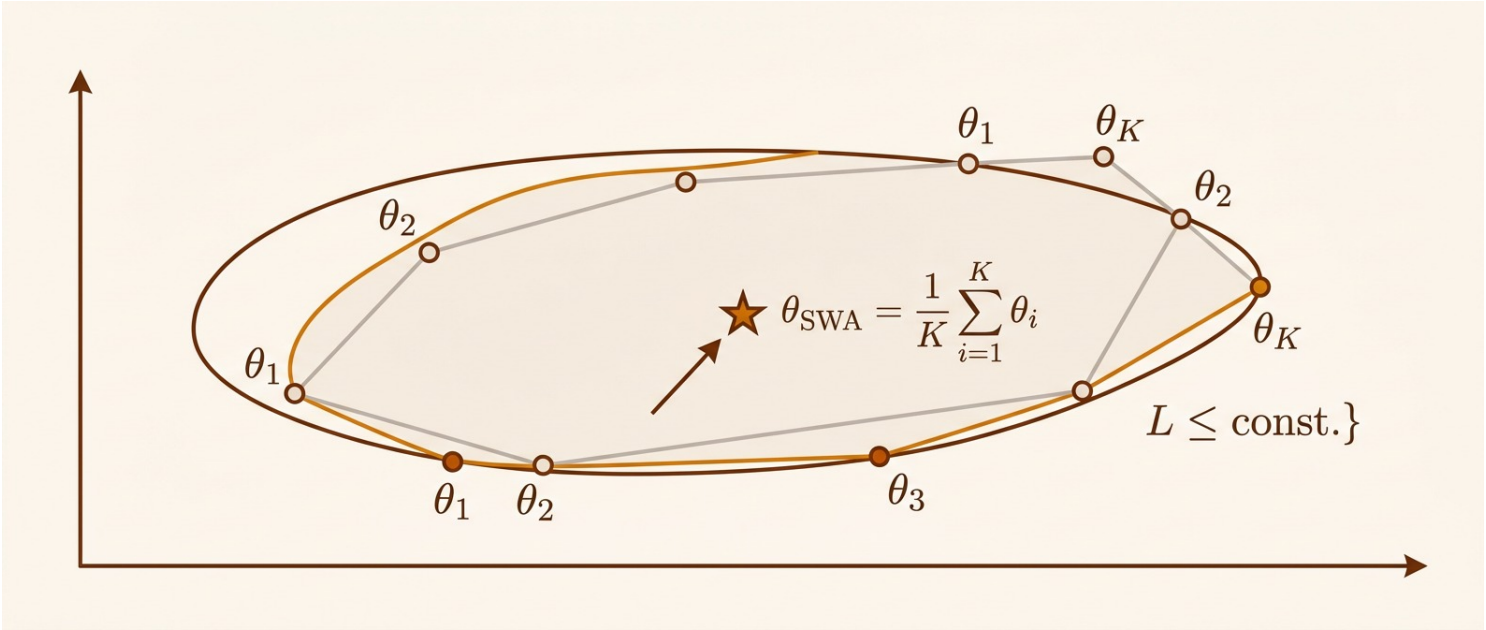



Рис. 9: Вид сверху: изолиния оврага, theta_k и центроид theta_SWA

### Геометрическое центрирование (Центр масс траектории)

Как показано на схематическом рисунке изолиний нерегулярного несимметричного оврага, точки $\theta_1, \theta_2, \theta_3$, полученные в конце фаз циклического SGD, равномерно распределены вдоль периферийной внешней границы сублевел-множества.

- В силу квазивыпуклости локального поперечного сечения долины, операция арифметического усреднения (построение выпуклой комбинации точек) находит **геометрический центр масс** замкнутой траектории.
- Полученная точка $\theta_{\text{SWA}}$ физически перемещается с периферии внутрь бассейна, оказываясь на максимальном удалении от крутых стенок.

### Радикальное снижение спектральной кривизны

Спектральный анализ Гессиана в точке $\theta_{\text{SWA}}$ показывает фундаментальное падение жесткости ландшафта по сравнению с финальной точкой стандартного стохастического спуска $\theta_{\text{SGD}}$:

1. Максимальное собственное число падает в несколько раз:
$$\lambda_{\max}(H(\theta_{\text{SWA}})) \ll \lambda_{\max}(H(\theta_{\text{SGD}}))$$
2. След Гессиана (интегральная кривизна) снижается на порядки:
$$\text{Tr}(H(\theta_{\text{SWA}})) \ll \text{Tr}(H(\theta_{\text{SGD}}))$$

**Механизм прироста обобщающей способности**

Поскольку точка $\theta_{\text{SWA}}$ лежит в геометрическом центре широкого и пологого дна бассейна, она обладает максимальным запасом геометрической устойчивости (margin). При сдвиге истинного ландшафта тестовых данных $L_{\text{test}}$ относительно обучающего $L_{\text{train}}$ точка $\theta_{\text{SWA}}$ остается в низкоуровневой зоне потерь, обеспечивая стабильное снижение тестовой ошибки без изменения вычислительного бюджета на инференсе.

---

## Современный фронтир: регуляризация кривизны (SAM) и ландшафты LLM

Исследования спектральной геометрии ландшафта сформировали современные подходы к регуляризации больших архитектур и объяснили динамику обучения сверхпараметризованных языковых моделей.

**Оптимизация с учетом остроты (Sharpness-Aware Minimization, SAM)**

Алгоритм SAM (Foret et al., 2021) напрямую внедряет минимизацию окрестностной остроты в целевую функцию. Вместо поиска изолированного минимума потерь SAM решает минимаксную задачу поиска центра гладкого шара с минимальным наихудшим значением потерь:
$$\min_{\theta} L^{\text{SAM}}(\theta), \quad \text{где } L^{\text{SAM}}(\theta) = \max_{\|\epsilon\|_2 \le \rho} L(\theta + \epsilon)$$

Реализация алгоритма опирается на два шага на каждой итерации:

1. **Шаг наихудшего возмущения:** Аппроксимируя функцию внутри шара радиуса $\rho$ рядом Тейлора первого порядка ($L(\theta+\epsilon) \approx L(\theta) + \epsilon^T \nabla L(\theta)$), находим вектор максимального локального возрастания ошибки по неравенству Коши-Буняковского:
$$\epsilon^*(\theta) = \arg\max_{\|\epsilon\|_2 \le \rho} \epsilon^T \nabla L(\theta) = \rho \frac{\nabla L(\theta)}{\|\nabla L(\theta)\|_2}$$
2. **Шаг оптимизации:** Вычисляется градиент потерь в наихудшей возмущенной точке $\theta + \epsilon^*$, и веса обновляются стандартным оптимизатором из исходной точки:
$$\theta \leftarrow \theta - \eta \nabla L(\theta + \epsilon^*(\theta))$$

Разложение градиента SAM показывает, что он в явном виде содержит регуляризатор кривизны:
$$\nabla L(\theta + \epsilon^*) \approx \nabla L(\theta) + \rho \frac{H(\theta)\nabla L(\theta)}{\|\nabla L(\theta)\|_2}$$

SAM штрафует точки с большими значениями собственных чисел Гессиана вдоль вектора градиента. Применение SAM стало критическим стандартом для обучения моделей Vision Transformer (ViT), где отсутствие пространственных индуктивных смещений сверток компенсируется принудительным поиском сверхплоских минимумов.

**Спектральная геометрия сверхпараметризованных LLM**

С ростом масштаба трансформерных моделей до сотен миллиардов параметров спектральная структура ландшафта выходит на свой теоретический асимптотический предел:

- **Схлопывание Bulk в сингулярность:** При экстремальной сверхпараметризации практически весь массив Bulk сжимается в сингулярную $\delta$-функцию Дирака в нуле: $\rho_{\text{bulk}}(\lambda) \to \delta(0)$. Модель приобретает колоссальное непрерывное связное многообразие нулевого лосса.
- **Феномен Grokking (Запоздалое обобщение):** В задачах алгоритмического и логического вывода модели часто достигают $100\%$ точности на обучающей выборке (Zero Train Loss), но имеют нулевую точность на тесте. Однако при продолжении градиентного спуска далеко за пределы нулевой ошибки (overtraining на миллионы шагов с Weight Decay) происходит внезапный скачок тестовой точности до $100\%$.

Геометрический анализ показывает, что в фазе запоздалого обобщения регуляризация весов медленно проталкивает параметры модели через энергетический барьер ландшафта из узкого «запомненного» минимума с высоким следом Гессиана в глобально плоский, высокосимметричный минимум, соответствующий структурированному обобщающему алгоритму. Понимание и контроль спектра Гессиана превращаются из абстрактной математической теории в главный инструмент управления поведением фундаментальных систем искусственного интеллекта.