Геометрия ландшафта потерь: структура спектра Гессиана, измерение остроты и механизмы оптимизации

Ключевая цель: Связать микроструктуру кривизны функции потерь (спектр матрицы вторых производных) с динамикой оптимизаторов (Adam, SWA) и способностью глубоких сетей к обобщению.

Основные темы:

- Локальная квадратичная геометрия и вычислительный аппарат анализа кривизны.
- Феномен спектрального расщепления: «Bulk + Outliers».
- Острота минимумов, парадокс масштабирования и режим «Edge of Stability».
- Почему Adam работает: геометрия предобусловливания сильно анизотропных ущелий.
- Стохастическое усреднение весов (SWA) как метод центрирования в нерегулярных долинах.

Нейроколлапс (Neural Collapse)

- Геометрический нейроколлапс — это удивительный и строго математический процесс скрытой геометрической гармонизации, который происходит в предпоследнем слое (penultimate layer) глубоких классификационных нейросетей на финальной стадии обучения.
- Папян и соавторы декомпозировали это на **4 проявления**:

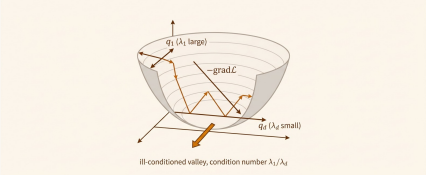
1. Коллапс внутриклассовой вариативности - все векторы картинок одного и того же класса сжимаются (коллапсируют) практически в одну идеальную точку.
2. Сходимость к структуре Simplex Equiangular Tight Frame (симплексный прямоугольный плотный фрейм) - точки разных классов выстраиваются в пространстве в максимально удаленную и симметричную геометрическую фигуру.
3. Последний слой нейросети — это линейный классификатор, векторы весов которого идеально сонаправлены с векторами классов из предпоследнего слоя.
4. Вся сложная математика принятия решений на последнем слое сети коллапсирует до простейшего правила: найти ближайший центр идеального класса (Nearest-Class-Center decision rule).

- До этой работы глубокие нейросети считались «черными ящиками». Декомпозиция Папяна показала, что в процессе минимизации ошибки современные архитектуры (ResNet, MLP и др.) независимо от воли инженеров стремятся к абсолютной геометрической простоте и симметрии.

Локальная квадратичная модель ландшафта потерь

- В малой окрестности точки $\theta \in \mathbb{R}^d$ гладкая функция потерь $L(\theta)$ аппроксимируется рядом Тейлора 2-го порядка:

$$L(\theta + \Delta\theta) \approx L(\theta) + \nabla L(\theta)^T \Delta\theta + \frac{1}{2}\Delta\theta^T H(\theta)\Delta\theta$$



- **Матрица Гессиана** $H(\theta) \in \mathbb{R}^{d\times d}$ — симметричная матрица вторых частных производных: $H_{ij} = \frac{\partial^2 L(\theta)}{\partial\theta_i \partial\theta_j}$
- **Спектральное разложение:** в силу симметрии $H = Q\Lambda Q^T = \sum_{i=1}^{d} \lambda_i q_i q_i^T$, где:
  - $\lambda_1 \geq \lambda_2 \geq \ldots \geq \lambda_d$ — собственные числа (кривизна функции вдоль главных осей).
  - q_i — ортонормированные собственные векторы (направления главных кривизн).
- **Типы критических точек** ($\nabla L(\theta^*) = 0$)**:**
  - **Локальный минимум:** необходимое условие 2-го порядка — $H(\theta^*) \succeq 0$ (все $\lambda_i \geq 0$). Достаточное для строгого минимума — $H(\theta^*) \succ 0$ ($\lambda_i > 0$).
  - **Седловая точка:** спектр содержит как положительные, так и отрицательные значения ($\lambda_1 > 0 > \lambda_d$).

Вычислительный барьер: квадратичная память и кубическая сложность

- Современные нейросети содержат экстремальное число параметров d:
  - **ResNet-50:** $d \approx 2.5 \times 10^7$ (25 млн параметров).
  - **LLaMA-3 (8B):** $d \approx 8.0 \times 10^9$ (8 млрд параметров).
- **Ограничение по памяти**: матрица H имеет размер $d \times d$. Хранение плотной матрицы в `float32` требует $4 \cdot d^2$ байт:
  - Для **ResNet-50** ($d = 2.5 \times 10^7$): $(2.5 \times 10^7)^2 \times 4$ Б $\approx 2.5 \times 10^{15}$ Б $=$ **2 500** ТБ
  - Для **LLaMA-3 (8B)** ($d = 8 \times 10^9$): $(8 \times 10^9)^2 \times 4$ Б $\approx 2.56 \times 10^{20}$ Б $=$ **256** Экзабайт
    (Для сравнения: весь мировой объем оперативной памяти дата-центров меньше этой величины).
- **Ограничение по времени:** Прямая диагонализация матрицы $d \times d$ (QR-алгоритм) требует $\mathcal{O}(d^3)$ операций.
- **Вывод:** Явное формирование, хранение и факторизация Гессиана **физически невозможны**.
- **Решение:** Подходы класса **Hessian-Free**, оперирующие исключительно неявными матрично-векторными произведениями Hv.

Hessian-Free подходы и трюк Перлмуттера

- **Hessian-Vector Product (HVP)** Hv представляет собой **направленную производную** градиента:

$$Hv = \nabla^2 L(\theta)v = \lim_{\epsilon \to 0} \frac{\nabla L(\theta + \epsilon v) - \nabla L(\theta)}{\epsilon} = \frac{\partial}{\partial \alpha} \nabla L(\theta + \alpha v)\Big|_{\alpha=0}$$

- Ее можно вычислить через двойное автодифференцирование:

1. Вычисляется скаляр — проекция градиента на вектор v: $\phi(\theta) = \langle \nabla_\theta L(\theta), v \rangle$
2. Вычисляется градиент от полученного скаляра по θ (при фиксированном v):

$$\nabla_\theta \phi(\theta) = \nabla_\theta (\nabla_\theta L(\theta)^T v) = \nabla^2_\theta L(\theta) v = Hv$$

- **Реализация в PyTorch:**

```
# Шаг 1: вычисляем градиент с сохранением вычислительного графа
grad_L = torch.autograd.grad(loss, params, create_graph=True)
# Шаг 2: дифференцируем скалярное произведение grad_L * v
Hv = torch.autograd.grad(grad_L, params, grad_outputs=v)
```

- **Вычислительная цена HVP:**
  - **Время:** ≈ 2–$3\times$ относительно стандартного backward pass (никаких $\mathcal{O}(d^2)$).
  - **Память:** $\mathcal{O}(\text{активации} + d)$ — требует хранения промежуточных узлов вычислительного графа для второго прохода.

Численный анализ спектра: метод Ланцоша и SLQ

Итерации Ланцоша (Lanczos Algorithm): поиск экстремальных λ

- Построение ортонормированного базиса подпространства Крылова:

$$\mathcal{K}_m(H, v) = \text{span}\{v, Hv, H^2v, \dots, H^{m-1}v\}, \quad m \ll d$$

- Система векторов $\{v, Hv, H^2v, \dots, H^{m-1}v\}$ ортогонализуется методом Ланцоша (ортогонализация Грамма-Шмидта для симметричных матриц). Обозначим результат $\{q_1, q_2, \dots, q_m\}$.
- Проекция Гессиана на $\mathcal{K}_m$ дает симметричную трехдиагональную матрицу $T_m \in \mathbb{R}^{m \times m}$. Док-во: $Hq_j \in \mathcal{K}_{j+1}$, поэтому элементы ниже первой поддиагонали равны нулю. Так как матрица симметричная, то будут равны нулю и верхние элементы.
- Экстремальные собственные числа матрицы T_m (числа Ритца) экспоненциально быстро сходятся к границам спектра Гессиана ($\lambda_{\max}, \lambda_{\min}$) всего за $m \sim 20$–100 вычислений HVP.

Численный анализ спектра: метод Ланцоша и SLQ

Стохастическая квадратура Ланцоша (SLQ): оценка всей формы спектра

- **Цель:** оценить непрерывную спектральную плотность (ESD): $\rho(\lambda) = \frac{1}{d}\sum_{i=1}^{d}\delta(\lambda - \lambda_i)$.
- **Шаг 1 (След функции):** Интеграл от любой гладкой тестовой функции $f(\lambda)$ (например, гауссова сглаживания) по спектру — это след матрицы:

$$\int f(\lambda)\rho(\lambda)d\lambda = \frac{1}{d}\sum_{i=1}^{d} f(\lambda_i) = \frac{1}{d}\mathrm{Tr}(f(H))$$

- **Шаг 2 (Оценка Хатчинсона):** След заменяется средним по случайным векторам v_k:

$$\mathrm{Tr}(f(H)) \approx \frac{1}{N_v}\sum_{k=1}^{N_v} v_k^T f(H) v_k, \quad v_k \sim \mathcal{N}(0, I_d) \text{ или Rademacher}(\pm 1)$$

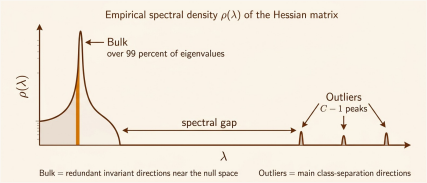
- **Шаг 3 (Квадратура Гаусса через T_m):** Запуск m шагов Ланцоша из вектора v_k сводит квадратичную форму $v_k^T f(H) v_k$ к вычислению функции от матрицы T_m размера $m \times m$:

$$v_k^T f(H) v_k \approx \|v_k\|^2 e_1^T f(T_m) e_1$$

Итог: Восстановление распределения миллиардов собственных значений нейросети за несколько сотен вычислений HVP без построения матрицы Гессиана.

Эмпирический спектр Гессиана: «Bulk + Outliers»

- **Гессиан потерь** $H = \nabla^2_\theta L(\theta) \in \mathbb{R}^{d \times d}$ описывает локальную кривизну функции потерь в пространстве параметров размерности d ($d \sim 10^6 - 10^{11}$).
- В работах Sagun et al. (2016, 2017) и Papyan (2018–2020) открыта универсальная макроструктура спектра (набора собственных чисел $\lambda_1 \leq \ldots \leq \lambda_d$) обученных сетей:



- **Непрерывный массив околонулевых значений («Bulk»):**
  - Подавляющее большинство собственных чисел ($> 99\%$) сосредоточено в узком интервале около нуля: $\lambda_i \approx 0$.
  - Означает локальную вырожденность кривизны: поверхность потерь практически плоская по подавляющему большинству направлений.
- **Изолированные выбросы («Outliers»):**
  - Небольшая группа аномально больших дискретных значений, отделённых от основного массива широкой **спектральной щелью (spectral gap)**.
  - Именно эти немногочисленные направления задают максимальную жесткость оптимизации и определяют величину $\lambda_{\max}$ (критическую для выбора learning rate).

Анатомия Гессиана: расщепление на компоненту Гаусса-Ньютона и невязки

- Рассмотрим задачу минимизации эмпирического риска: $L(\theta) = \frac{1}{N}\sum_{i=1}^{N} \ell(f(x_i;\theta), y_i)$ где $f(x_i;\theta) \in \mathbb{R}^C$ — выход сети (логиты), а ℓ — функция потерь (например, Cross-Entropy).
- По правилу дифференцирования сложной функции Гессиан $H \in \mathbb{R}^{d\times d}$ раскладывается на две матрицы: $H = G + E$.
- **1. Обобщённая матрица Гаусса-Ньютона (Generalized Gauss-Newton, GGN):**

$$G = \frac{1}{N}\sum_{i=1}^{N} J_i^T \left[\nabla_f^2 \ell(f(x_i;\theta), y_i)\right] J_i$$

  где $J_i = \frac{\partial f(x_i;\theta)}{\partial \theta} \in \mathbb{R}^{C\times d}$ — матрица Якоби сети для i-го примера.
- **2. Матрица невязок:** $E = \frac{1}{N}\sum_{i=1}^{N}\sum_{c=1}^{C} [\nabla_f \ell]_c \cdot \nabla_\theta^2 f_c(x_i;\theta)$
- **В окрестности хорошего минимума:** Модель хорошо обучена (интерполяция) $\Longrightarrow$ вектор ошибок $[\nabla_f \ell] \approx 0 \implies \|E\| \ll \|G\|$. Следовательно, **спектр Гессиана H почти полностью определяется матрицей G.**

Происхождение выбросов: декомпозиция Папяна

- В задачах классификации на C классов число спектральных выбросов **строго равно** $C-1$ (либо C). Откуда берётся это число?
- Матрица G строится через гессиан потерь по логитам $\nabla_f^2 \ell$. Для Cross-Entropy так как $\nabla_f \ell = p - y$, то:

$$\nabla_f^2 \ell = \mathrm{diag}(p) - pp^T \quad \Longrightarrow \quad \mathrm{rank}(\nabla_f^2 \ell) = C - 1$$

(ранг равен $C-1$, так как вектор вероятностей нормирован: $\sum_{c=1}^{C} p_c = 1$. Домашнее задание: выведите формулу выше и докажите утверждение про ранг, просуммировав элементы каждой строки).

- **Декомпозиция Папяна (Papyan, 2020):** Папян разделил градиенты выходов на средние по классам и внутриклассовый разброс (формулы получились громоздкие):

$$G = G_{\text{cross}} + G_{\text{within}}$$

- G_{cross} **(межклассовая кривизна):** формируется средними по классам градиентами логитов, и ранг матрицы G_{cross} **строго равен** $C-1$.
- G_{within} **(внутриклассовая кривизна):** сумма ковариаций градиентов лллогитов внутри каждого класса. Порождает плотный спектральный шум (Bulk).

Физический смысл направлений

Характеристика	«Жёсткие» оси (Outliers, $k \leq C-1$)	«Мягкие» оси (Bulk, $k > C$)
Кривизна (λ_k)	Экстремально высокая ($\lambda_k \gg 0$)	Околонулевая ($\lambda_k \approx 0$)
Чувствительность потерь	Шаг $\Delta\theta$ вызывает резкий скачок функции потерь	Шаг $\Delta\theta$ почти не меняет значение потерь
Геометрическая роль	Разделение классов (межклассовая геометрия)	Избыточная емкость сети
Динамика оптимизации	Быстро сходятся	Дрейфуют под действием стохастического шума SGD
Размерность подпространства	Низкая ($C-1 \ll d$)	Почти всё пространство параметров ($\approx d$)

Геометрическая картина дна функции потерь: Ландшафт потерь — это не симметричная чаша. Это **сверхдлинный плоский каньон (желоб)**:

- **Поперёк каньона** (по $C-1$ жестким осям) — отвесные вертикальные стены: шаг в сторону разрушает разделение классов.
- **Вдоль каньона** (по миллионам мягких осей Bulk) — плоское дно: параметры могут свободно блуждать без потери точности предсказаний.

Формализация остроты минимума (Sharpness)

Как строго выразить интуитивное понятие «остроты» точки минимума θ^*?

- **1. Спектральная норма Гессиана (наихудшая локальная кривизна):**

$$\text{Sharpness}_\lambda = \lambda_{\max}(H) = \|H\|_2, \quad \text{где } H = \nabla^2 L(\theta^*) \succeq 0$$

  Оценивает максимальную крутизну стенок функции потерь вдоль собственного вектора q_1, соответствующего $\lambda_{\max}$.

- **2. След Гессиана (усредненная кривизна по всем направлениям):**

$$\text{Tr}(H) = \sum_{i=1}^{d} \lambda_i = d \cdot \mathbb{E}_{v \sim \mathcal{S}^{d-1}}[v^T H v]$$

  Характеризует среднюю кривизну ландшафта (в отличие от определителя $\det(H)$, задающего объем эллипсоида потерь).

- **3. Окрестностная острота (ϵ-sharpness / Keskar et al., Foret et al.):**

$$\mathcal{S}_\rho(\theta^*) = \max_{\|\epsilon\|_2 \le \rho} [L(\theta^* + \epsilon) - L(\theta^*)]$$

  Не требует вычисления вторых производных; ищет худшее возмущение параметров в евклидовом шаре радиуса ρ.

  В точке оптимума ($\nabla L(\theta^*) = 0$) при малом ρ: $\mathcal{S}_\rho(\theta^*) \approx \frac{1}{2}\rho^2 \lambda_{\max}(H)$.

Дилемма «Плоские vs Острые минимумы» и обобщающая способность

Классическая гипотеза (Hochreiter & Schmidhuber, 1997): Плоские минимумы (Flat Minima) обеспечивают лучшую обобщающую способность, чем острые (Sharp Minima).

Механизм чувствительности к шуму выборки (Sample Variance):

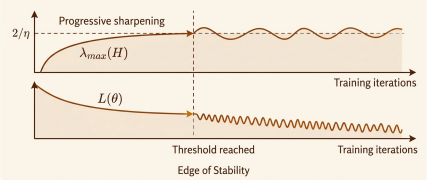
- Эмпирический риск $L_{\text{train}}(\theta)$ отличается от истинного риска $L_{\text{test}}(\theta)$ из-за конечного размера обучающей выборки.
- Это вызывает смещение положения точки оптимума: $\theta^*_{\text{test}} \approx \theta^*_{\text{train}} + \Delta\theta$.
- В **остром минимуме** смещение $\Delta\theta$ приводит к резкому росту тестовой ошибки вдоль жестких направлений:

$$L_{\text{test}}(\theta^*_{\text{train}}) - L_{\text{test}}(\theta^*_{\text{test}}) \approx \frac{1}{2}\Delta\theta^T H \Delta\theta \sim \frac{1}{2}\lambda_{\max}\|\Delta\theta\|^2$$

- В **плоском минимуме** кривизна мала по всем направлениям $\Longrightarrow$ ошибка на тесте остается практически на уровне обучающей.

Динамика обучения на грани устойчивости (Edge of Stability)

- **Классическая оптимизация (локально-квадратичная модель):**
  - Градиентный спуск с постоянным шагом η гарантированно локально сходится, только если: $\eta < \frac{2}{\lambda_{\max}(H)}$
  - При $\eta > 2/\lambda_{\max}$ квадратичная модель предсказывает катастрофическую расходимость (взрыв градиентов).



- **Открытие Cohen et al. (2021) — режим Edge of Stability (EoS):**
  - **Прогрессивное заострение:** В глубоких нейросетях при GD кривизна $\lambda_{\max}(H)$ стабильно растет на ранних этапах.
  - **Выход на грань:** Достигнув порога неустойчивости $\lambda_{\max} \approx 2/\eta$, сеть **не расходится**.
  - **Самостабилизация:** Оптимизатор входит в нелинейный режим: $\lambda_{\max}$ колеблется вблизи $2/\eta$, потери испытывают локальные осцилляции вдоль ведущих собственных направлений (спектральных выбросов Гессиана), но в среднем продолжают минимизироваться.
- **Смена парадигмы:** Глубокое обучение функционирует за пределами зоны монотонной сходимости классической оптимизации — на динамической грани хаоса и устойчивости.

Патология SGD: сверхузкие овраги и число обусловленности

- В окрестности локального минимума аппроксимируем функцию потерь квадратичной формой: $L(\theta) \approx L(\theta^*) + \frac{1}{2}(\theta - \theta^*)^T H(\theta - \theta^*)$
- В **собственном базисе Гессиана** ($Hv_k = \lambda_k v_k$) шаг градиентного спуска распадается на независимые координаты: $\Delta\theta_{t+1}^{(k)} = (1 - \eta\lambda_k)\Delta\theta_t^{(k)}$, где $\Delta\theta_t = \theta_t - \theta^*$
- **Спектральная структура ландшафта в Deep Learning:** Выбросы (Outliers, $\lambda_{\max}$) + Основная масса (Bulk, λ_{bulk}). Число обусловленности: $\kappa = \frac{\lambda_{\max}}{\lambda_{\min}} \approx \frac{\lambda_{\text{outlier}}}{\lambda_{\text{bulk}}} \gg 10^4$–$10^6$.
- **Дилемма шага обучения в анизотропном ущелье:**
  - **Устойчивость вдоль крутых стенок (Outliers):** требует малого шага: $\eta < \frac{2}{\lambda_{\max}}$.
  - **Сходимость вдоль пологого дна (Bulk):** при $\eta \approx \frac{2}{\lambda_{\max}}$ фактор сжатия ошибки составляет:
$$(1 - \eta\lambda_{\text{bulk}}) \approx 1 - \frac{2\lambda_{\text{bulk}}}{\lambda_{\max}} = 1 - \frac{2}{\kappa}$$
- **Катастрофическое замедление:** Для продвижения вдоль дна оврага на базовое расстояние оптимизатору требуется $\mathcal{O}(\kappa)$ шагов. Спуск практически парализован.

Архитектура Adam: адаптивное диагональное масштабирование

- Алгоритм **Adam** (Kingma & Ba, 2014) решает проблему разброса масштабов через сглаживание первого и второго моментов градиента:

  $m_t = \beta_1 m_{t-1} + (1-\beta_1) g_t$ (первый момент, экспоненциальное сглаживание направления)

  $v_t = \beta_2 v_{t-1} + (1-\beta_2) g_t^2$ (нецентрированный второй момент, оценка энергии по координатам)

  (где $g_t^2 = g_t \odot g_t$ — покомпонентный квадрат вектора градиента)
- **Коррекция смещения к нулю на первых итерациях:**

$$\hat{m}_t = \frac{m_t}{1-\beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1-\beta_2^t}$$

- **Правило обновления весов:**

$$\theta_{t+1} = \theta_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}$$

  (деление векторов и взятие корня выполняются покомпонентно)
- **Ключевой механизм:** Деление на $\sqrt{\hat{v}_t} + \epsilon$ нормализует скорость движения: каждый параметр обновляется со своей индивидуальной скоростью.

Геометрическая интерпретация: диагональное предобусловливание

- **Идеал оптимизации второго порядка (метод Ньютона):**

$$\theta_{t+1} = \theta_t - \eta H^{-1} \nabla L(\theta_t)$$

  Матрица H^{-1} полностью ликвидирует анизотропию: число обусловленности предобусловленной системы $\kappa(H^{-1}H) = 1$.

- **Adam как дешевая диагональная аппроксимация:**
  Покомпонентный квадрат градиента приближает диагональ матрицы Гаусса-Ньютона (или эмпирического Фишера): $\mathbb{E}[g_i^2] \approx \text{diag}(H)_{ii}$

  Деление на $\sqrt{v_t}$ действует как **предобусловливатель Якоби**: $\text{diag}\left(\frac{1}{\sqrt{v_t}+\epsilon}\right) \approx \text{diag}(H)^{-1/2}$

- **Геометрия преобразования координат:**
  Оператор масштабирует координаты: $\tilde{\theta} = \text{diag}(H)^{1/2}\theta$.
  В деформированном базисе изолинии функции потерь сжимаются из сверхвытянутых «эллиптических оврагов» в близкие к сферическим формы вдоль осей параметров.

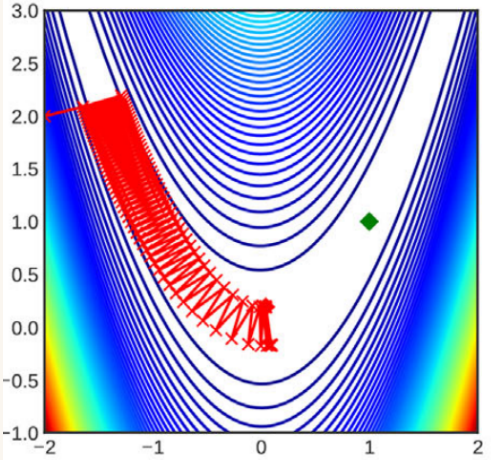
Геометрическая интерпретация: доказательство

- С точки зрения математического анализа утверждение, что квадрат первой производной $(f')^2$ равен второй производной f'', для произвольной функции звучит абсурдно. Но в ML оптимизируют не произвольные функции, а функции потерь, основанные на вероятностных моделях — **отрицательное логарифмическое правдоподобие**: $L(\theta) = -\log p(y \mid x, \theta)$. К этому виду сводятся и кросс-энтропия, и MSE при предположении нормального шума.
- **Тождество для информационной матрицы Фишера (второе тождество Бартлетта)**. Интеграл плотности вероятности равен единице: $\int p(y \mid \theta)\, dy = 1$. Продифференцировав это тождество по параметру θ дважды, получим:

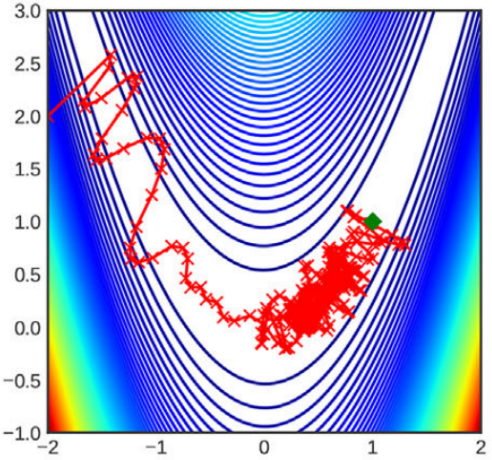
$$\mathbb{E}_{y \sim p_\theta}\left[\nabla^2(-\log p(y \mid \theta))\right] = \mathbb{E}_{y \sim p_\theta}\left[\nabla(-\log p(y \mid \theta)) \cdot \nabla(-\log p(y \mid \theta))^T\right]$$

  Левая часть — это **математическое ожидание Гессиана** $\mathbb{E}[H]$. Правая часть — это **ковариация градиентов** (матрица Фишера F).
- Единственный не обоснованный теоретически прием - деление на $\sqrt{v_t}$ (по теории нужна 1-я степень). Это следствие практических соображений: на пологих плато при делении на v_t шаг улетит в бесконечность. Вторая причина: растяжение пространства $\tilde{\theta} = H^{1/2}\theta$ нормирует производные по разным координатам.

Спектральная трансформация: как Adam выравнивает динамику

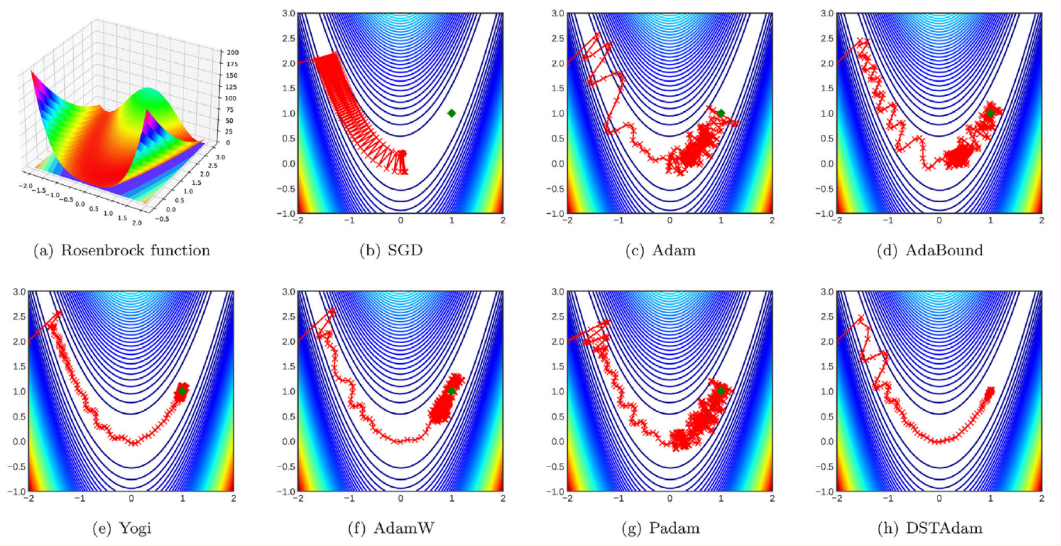


(b) SGD



(c) Adam

Другие оптимизаторы



(a) Rosenbrock function (b) SGD (c) Adam (d) AdaBound

(e) Yogi (f) AdamW (g) Padam (h) DSTAdam

Реальная топология минимумов: асимметричные ущелья

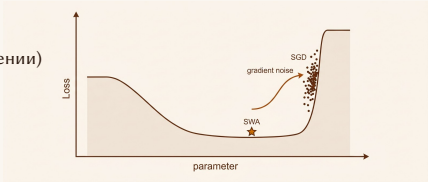
- **Крах классической интуиции:** Привычная ментальная модель оптимизации в виде симметричной чаши («параболоида») в сверхпараметризованных сетях не работает.
- **Свойства реального ландшафта функции потерь:**
  - **Асимметрия крутизны:** Профиль дна напоминает овраг с несимметричными стенками — с одной стороны обрывистый склон, с другой — пологая равнина.
  - **Связность минимумов (Mode Connectivity):** Изолированные локальные минимумы почти всегда соединены непрерывными путями с околонулевым барьером функции потерь (Garipov et al., Draxler et al., 2018).
  - **Искривленность дна долины:** Из-за нелинейностей функций активаций дно ущелья представляет собой многомерную искривленную гиперповерхность, а не прямую линию.
- **Геометрия сублевел-множеств (областей низкого лосса):** Сложные ветвящиеся каньоны с резкими границами кривизны и колоссальным объемом квази-нулевой кривизны вдоль преимущественных направлений.

Почему стохастический градиентный спуск застревает на краях долин?

- **Природа стохастического шума градиента:**

  $g_t(\theta) = \nabla L(\theta) + \xi_t, \quad \xi_t \sim \mathcal{N}(0, \Sigma(\theta))$ (в диффузионном приближении)

  Ковариационная матрица шума $\Sigma(\theta)$ сильно анизотропна: ее главные оси коррелируют с собственными направлениями матрицы Гаусса-Ньютона.



- **Энтропийное выталкивание (Entropic Force):**
  - В пространствах сверхвысокой размерности ($d \sim 10^7 - 10^{11}$) практически весь объем сосредоточен в тонкой приповерхностной оболочке («проклятие размерности»).
  - Стохастический шум градиента вместе с конечным шагом обучения (η) играет роль тепловой энергии, выталкивающей траекторию SGD из геометрического центра долины к ее крутым границам.
- **Следствие:** Финальная точка стандартного SGD/Adam лежит на склоне с высоким значением максимальной кривизны ($\lambda_{\max}(H)$), что ухудшает устойчивость модели к сдвигу тестовых данных.

Алгоритм Stochastic Weight Averaging (SWA)

- **Идея метода (Izmailov et al., 2018):** Отказ от сходимости в одну граничную точку в пользу усреднения траектории движения внутри долины.
- **Этапы алгоритма:**

1. **Спуск к долине:** Стандартный прогрев (Warmup) и спуск с убывающим темпом обучения до выхода на плато.
2. **Исследование долины:** Переключение на постоянный умеренно-высокий или циклический темп обучения $\eta(t)$ (Cyclic/Cosine LR). Оптимизатор циклически исследует окрестность, не «замерзая» на стенках.
3. **Сбор контрольных точек:** Сохранение весов θ_k в конце каждого цикла.

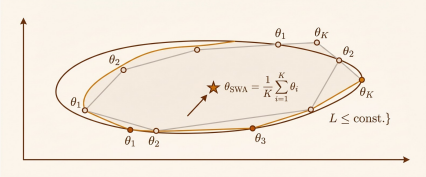
- **Усреднение весов во времени:**

$$\theta_{\text{SWA}} = \frac{1}{K}\sum_{k=1}^{K}\theta_k \quad \Longleftrightarrow \quad \theta_{\text{SWA}}^{(k)} = \frac{k \cdot \theta_{\text{SWA}}^{(k-1)} + \theta_k}{k+1}$$

- **Критический шаг — финализация BatchNorm:** Поскольку активации слоев нелинейно зависят от весов, усреднение θ делает невалидными накопленные статистики μ и σ^2. Необходим **один проход по данным** (достаточно без градиентов) с усредненным θ для вычисления корректных статистик BN.

Геометрический эффект SWA: центрирование в долине

- **Центр масс траектории:** Траектория SGD с циклическим LR обходит периферию локального бассейна. В силу локальной квазивыпуклости сечения долины, арифметическое среднее точек θ_{SWA} оказывается внутри бассейна, далеко от его крутых стенок.



- **Радикальное падение кривизны (остроты):**
  - Максимальное собственное число Гессиана падает:

$$\lambda_{\max}\big(H(\theta_{\text{SWA}})\big) \ll \lambda_{\max}\big(H(\theta_{\text{SGD}})\big)$$

  - След Гессиана $\text{Tr}(H) = \sum_j \lambda_j$ (интегральная кривизна) уменьшается в разы.
- **Улучшение обобщающей способности (Generalization):** находясь в глубине плоского минимума (θ_{SWA}), модель сохраняет низкий лосс при возмущениях данных.

Современный фронтир: регуляризация кривизны (SAM) и ландшафты LLM

Sharpness-Aware Minimization (SAM, Foret et al., 2021):

- Прямой поиск плоских минимумов через минимаксную формулировку:

$$\min_{\theta} L^{\text{SAM}}(\theta), \quad \text{где} \quad L^{\text{SAM}}(\theta) = \max_{\|\epsilon\|_2 \leq \rho} L(\theta + \epsilon)$$

- **Двухшаговый алгоритм:**

1. Худшее локальное возмущение в радиусе ρ: $\epsilon^*(\theta) \approx \rho \frac{\nabla L(\theta)}{\|\nabla L(\theta)\|_2}$.
2. Реальный шаг оптимизатора из возмущенной точки: $\theta \leftarrow \theta - \eta \nabla L(\theta + \epsilon^*)$.

- Алгоритм штрафует области с высоким $\lambda_{\max}$, отдавая приоритет широким долинам.

Спектральная геометрия в эру Foundation Models и LLM:

- **Предел сверхпараметризации:** При росте числа параметров до сотен миллиардов спектральная плотность Bulk стягивается в δ-пик Дирака в нуле $\delta(0)$.
- **Феномен Grokking (запоздалое обобщение):** При длительном обучении за пределами нулевой ошибки регуляризация весов приводит к переходу решения через критический барьер — в качественно более плоский минимум, обеспечивающий внезапный рост обобщения.