# Лабораторная работа: Спектральная теория случайных матриц — от иллюзии шума к диагностике нейросетей

## Теоретический контекст

### 1. Закон Марченко–Пастура (MP)

В классической статистике ($n \to \infty$ при фиксированном $p$) выборочная ковариационная матрица сходится к истинной: $\|\hat{\Sigma}_n - \Sigma\| \to 0$. Однако в современном машинном обучении мы почти всегда находимся в режиме высокой размерности ($p, n \to \infty$, так что $p/n \to \gamma \in (0, \infty)$).

В этом режиме спектр выборочной ковариации даже для чистого некоррелированного стандартного белого шума ($\Sigma = \sigma^2 I_p$) не концентрируется в точке $\sigma^2$, а распределяется в непрерывный массив (**спектральный балк**, bulk), описываемый предельным законом Марченко–Пастура:

$$d\mu_{MP}(\lambda) = \left(1 - \frac{1}{\gamma}\right)^+ \delta_0(\lambda)\, d\lambda + \rho_{MP}(\lambda)\, d\lambda$$

где непрерывная плотность сосредоточена строго на отрезке $[\lambda_-, \lambda_+]$:

$$\rho_{MP}(\lambda) = \frac{1}{2\pi\sigma^2\gamma\lambda}\sqrt{(\lambda_+ - \lambda)(\lambda - \lambda_-)}\,\mathbf{1}_{[\lambda_-,\lambda_+]}(\lambda), \quad \lambda_\pm = \sigma^2(1 \pm \sqrt{\gamma})^2$$

Здесь $(x)^+ = \max(0, x)$, а $\delta_0(\lambda)$ — дельта-мера Дирака в нуле, отражающая появление ровно $p - n$ нулевых собственных значений при дефиците данных ($p > n \implies \gamma > 1$). Полная мера нормирована на единицу: $\int_0^\infty d\mu_{MP}(\lambda) = 1$.

### 2. Фазовый переход BBP (Baik–Ben Arous–Péché)

Если данные содержат полезный одномерный детерминированный сигнал мощности $\theta$ на фоне изотропного белого шума (модель одиночного шипа Джонстоуна):

$$\Sigma = I_p + \theta v_1 v_1^T, \quad \|v_1\|_2 = 1, \quad \theta > 0$$

то спектральный анализ выборочной ковариации $\hat{\Sigma} = \frac{1}{n} Y Y^T$ детектирует данный сигнал на макроуровне тогда и только тогда, когда его мощность строго превышает критический порог:

$$\theta > \theta_c = \sqrt{\gamma} = \sqrt{\frac{p}{n}}$$

Предельное поведение старшей спектральной пары $(\hat{\lambda}_1, \hat{v}_1)$ подчиняется кусочно-аналитическому закону: * **Асимптотика старшего собственного значения:**

$$\hat{\lambda}_1 \xrightarrow{a.s.} \begin{cases} \lambda_+ = (1 + \sqrt{\gamma})^2, & \theta \le \theta_c \\ (1 + \theta)\left(1 + \dfrac{\gamma}{\theta}\right), & \theta > \theta_c \end{cases}$$

* **Асимптотика перекрытия (квадрата косинуса) собственного вектора с истинным направлением:**

$$|\langle \hat{v}_1, v_1 \rangle|^2 \xrightarrow{a.s.} \begin{cases} 0, & \theta \le \theta_c \\ \dfrac{1 - \gamma/\theta^2}{1 + \gamma/\theta}, & \theta > \theta_c \end{cases}$$

В докритическом режиме полезный сигнал бесследно тонет в спектральном балке шума. В надкритическом режиме сигнал выталкивает собственное число за пределы балка, однако наблюдаемая выборочная дисперсия $\hat{\lambda}_1$ систематически завышает истинную энергию сигнала $(1+\theta)$, а реконструированный вектор остаётся скошен шумом.

### 3. Теория тяжелых хвостов в глубоком обучении (HTSR Мартина–Махони)

В глубоких нейросетях в процессе оптимизации (SGD) спектр корреляционной матрицы весов $S$ уходит от балка Марченко–Пастура и формирует степенной тяжелый хвост (Power Law):

$$\rho(\lambda) \propto \lambda^{-\alpha}, \quad \lambda \ge \lambda_{min}$$

* $\alpha \in (2, 4]$ — **«Зона Златовласки» (Goldilocks Phase):** оптимальная неявная регуляризация, отличная обобщающая способность. * $\alpha > 4$ или отсутствие степенного хвоста — **Слабообученный режим / Шум:** преобладание случайных MP-компонент. * $\alpha \le 2$ либо деградация непрерывного спектра — **Коллапс ранга / Переобучение:** чрезмерное сжатие размерности представления, потеря вариативности.

---

## Задание 1. Синтетический тест: Шумовой балк Марченко–Пастура

### Цель задания

Численно воспроизвести распределение Марченко–Пастура, исследовать поведение спектра в режимах полного и неполного ранга и научиться корректно согласовывать теоретические плотности с эмпирическими данными.

### Порядок выполнения:

1. **Генерация данных:** Напишите функцию, принимающую $p$ и $n$, которая генерирует матрицу белого шума $X \in \mathbb{R}^{p \times n}$, где $X_{ij} \sim \mathcal{N}(0, \sigma^2)$ с $\sigma^2 = 1.0$, формирует выборочную ковариационную матрицу $\hat{\Sigma} = \frac{1}{n} X X^T \in \mathbb{R}^{p \times p}$ и возвращает ее спектр (собственные значения), рассчитанный с помощью `scipy.linalg.eigh` или `numpy.linalg.eigvalsh`.
2. **Эксперимент в двух режимах (при фиксированном $n = 1000$):**
   - **Режим А (полный ранг):** $p = 500 \implies \gamma = 0.5$
   - **Режим В (дефект ранга):** $p = 2000 \implies \gamma = 2.0$
3. **Визуализация и сопоставление с теорией:** Для каждого режима постройте график:
   - Эмпирическую гистограмму плотности распределения собственных значений.
   - Поверх гистограммы — непрерывную аналитическую кривую $\rho_{MP}(\lambda)$.
   - Вертикальными пунктирными линиями отметьте теоретические границы балка $\lambda_-$ и $\lambda_+$.

**Методические предостережения к Режиму B ($\gamma = 2.0$):**

**Обратите внимание на численную специфику:** 1. При попытке прямолинейного отбора ненулевых собственных значений через условие `eigs > 0` стандартные численные солверы из-за ошибок округления выдадут часть нулевых собственных чисел как малые положительные величины (порядка $10^{-16}$), а часть — как отрицательные. Подумайте, какой порог фильтрации отсечет именно машинный ноль, не задев информативную часть спектра. 2. Если вы просто отфильтруете нули и построите гистограмму с параметром `density=True`, а затем наложите функцию $\rho_{MP}(\lambda)$ по приведенной формуле, **кривая и гистограмма разойдутся по высоте примерно в 2 раза**. Внимательно посмотрите на теоретическое выражение для полной меры $d\mu_{MP}(\lambda)$ в теории: чему равен интеграл от $\rho_{MP}(\lambda)$ по отрезку $[\lambda_-, \lambda_+]$ при $\gamma > 1$? Чему равен интеграл гистограммы с параметром `density=True`? Вам необходимо понять математическую причину этого расхождения и корректно согласовать масштабы теории и эксперимента (в отчете обязательно приведите математическое обоснование выбранного множителя масштабирования).

4. **Анализ результатов (включить в отчет):**
   - Сведите в таблицу теоретические значения $[\lambda_-, \lambda_+]$ и экспериментальные минимумы и максимумы ненулевого спектра $[\hat{\lambda}_{min}, \hat{\lambda}_{max}]$ для обоих режимов.
   - Совпали ли они абсолютно точно? Почему экспериментальный максимум $\hat{\lambda}_{max}$ систематически оказывается чуть правее теоретического предела $\lambda_+$? Какое распределение описывает эти флуктуации?
   - Ответьте на концептуальный вопрос: *почему для независимого некоррелированного шума при $p = n$ ($\gamma = 1$) максимальная дисперсия вдоль первой главной компоненты стремится к $4$, а не к $1$, хотя истинная дисперсия по всем направлениям строго равна $1$? В чем заключается геометрический и статистический смысл этого явления?*

---

## Задание 2. Фазовый переход BBP: Слепота PCA и калибровка искажений

Исследуйте предел обнаружения скрытого низкорангового сигнала в шуме высокой размерности.

**Параметры эксперимента:**

- Размерности: $p = 1500, n = 3000 \implies \gamma = 0.5$ ($\sigma^2 = 1$).
- Критический порог: $\theta_c = \sqrt{0.5} \approx 0.7071$.
- Границы балка шума: $\lambda_- = (1 - \sqrt{0.5})^2 \approx 0.0858$, $\lambda_+ = (1 + \sqrt{0.5})^2 \approx 2.9142$.
- Вектор сигнала: $v_1 = [1, 0, \dots, 0]^T \in \mathbb{R}^p$.

**Порядок выполнения:**

1. **Генерация данных Spiked-модели:** Реализуйте генерацию матрицы наблюдений:

$$Y = \left(I_p + \theta v_1 v_1^T\right)^{1/2} X, \quad X_{ij} \sim \mathcal{N}(0, 1), \quad X \in \mathbb{R}^{p \times n}$$

*(Оптимизация: оператор $\left(I_p + \theta v_1 v_1^T\right)^{1/2}$ сводится к масштабированию первой строки матрицы $X$ в $\sqrt{1 + \theta}$ раз).*

2. **Спектральный анализ:** Проитерируйте силу сигнала $\theta \in [0.1, 2.5]$ с шагом $0.1$. Для уменьшения флуктуаций конечной размерности усредните метрики по $M \geq 5$ независимым генерациям матрицы шума для каждого $\theta$:

   - Вычислите старшее собственное число $\hat{\lambda}_1$ и соответствующий собственный вектор $\hat{v}_1$ матрицы выборочной ковариации $\hat{\Sigma} = \frac{1}{n} Y Y^T$.
   - Вычислите квадрат скалярного произведения $|\langle \hat{v}_1, v_1 \rangle|^2$.

     **Предостережение к вычислению спектра:** Обратите внимание на то, как стандартные библиотечные функции (например, `numpy.linalg.eigh`) упорядочивают возвращаемые собственные значения и столбцы собственных векторов. Если взять первый попавшийся элемент массива «в лоб», ваш график $\hat{\lambda}_1$ окажется прижат к нижней границе $\lambda_-$, а скалярное произведение будет равно нулю во всём диапазоне. Подумайте, какой срез массива соответствует главному компоненту.

     *(Совет по производительности: полное спектральное разложение матрицы $1500 \times 1500$ ресурсоёмко. Вспомните связь между собственными значениями ковариации и сингулярными числами матрицы данных. Подумайте, как найти только максимальную спектральную компоненту существенно быстрее).*

3. **Визуализация и сопоставление с теорией:**

   - Постройте график зависимости выборочного $\hat{\lambda}_1$ от $\theta$. Наложите поверх теоретическую кривую BBP.
   - Постройте график перекрытия $|\langle \hat{v}_1, v_1 \rangle|^2$ от $\theta$. Наложите поверх теоретическую кривую предела Paul–Benaych-Georges.
   - Отметьте вертикальной пунктирной линией положение теоретического критического порога $\theta_c$.

     **Предостережение к теоретическим графикам:** Если вычислить аналитическую зависимость для $\hat{\lambda}_1$ по формуле $(1 + \theta)(1 + \gamma/\theta)$ «в лоб» на всей сетке значений, то при малых $\theta$ кривая устремится в $+\infty$, полностью разрушив масштаб графиков и войдя в прямое противоречие с экспериментом. Внимательно сопоставьте расчёт теории с кусочным определением феномена BBP в докритической и надкритической областях.

4. **Калибровка сигнала (Инверсия фазового перехода):** В надкритическом режиме выборочная дисперсия $\hat{\lambda}_1 - 1$ систематически завышает истинную силу сигнала $\theta$ из-за конструктивной интерференции с шумом балка. Теоретическая инверсия соотношения BBP позволяет восстановить несмещённую оценку $\hat{\theta}$:

$$\hat{\theta} = \frac{\hat{\lambda}_1 + 1 - \gamma + \sqrt{(\hat{\lambda}_1 + 1 - \gamma)^2 - 4\hat{\lambda}_1}}{2} - 1$$

   - Реализуйте функцию-валидатор (Guard clause), которая принимает на вход выборочное собственное значение $\hat{\lambda}_1$ и возвращает калиброванную оценку $\hat{\theta}$ либо вердикт: *«Сигнал отсутствует или находится ниже предела детектирования»*.
   - Постройте график сравнения истинного $\theta$, наивной оценки $\hat{\theta}_{\text{naive}} = \hat{\lambda}_1 - 1$ и калиброванной оценки $\hat{\theta}$ для диапазона $\theta \in [0.1, 2.5]$.

---

**Задание 3. Спектральная диагностика слоев ResNet-18 (Теория Мартина–Махони)**

Проведите аудит весовых матриц предобученной сети ResNet-18 без использования тестовых данных.

```
import torchvision.models as models
# Загрузка модели (~45 Мб)
model = models.resnet18(weights=models.ResNet18_Weights.DEFAULT)
```

**1. Извлечение матриц и спектральный анализ**

- Для полносвязного слоя (`fc`) используйте матрицу весов $W$ напрямую.
- Для сверточных слоев (`Conv2d`) формы $(C_{out}, C_{in}, K, K)$ выполните решейп в 2D-матрицу размера $C_{out} \times (C_{in} \cdot K \cdot K)$.
- Для матрицы слоя $W \in \mathbb{R}^{M \times K}$ нормированная корреляционная матрица определяется как $S = \frac{1}{N} WW^T$ (или $\frac{1}{N} W^T W$), где $N = \max(M, K)$.

  **Предупреждение:** Прямое перемножение $S = \frac{1}{N} W^T W$ для сверточных слоев с $C_{in} \cdot K^2 \gg C_{out}$ приведет к созданию матрицы $4608 \times 4608$, что крайне неэффективно и даст тысячи машинных нулей. **Подумайте:** Как через сингулярные числа $s_i$ матрицы весов $W$ или через выбор правильного порядка матричного умножения получить только физически значимые ненулевые собственные числа $\lambda_i$ за доли секунды?

**2. Исследование методов подгонки степенного закона (Power Law)** Выберите слой `layer4.1.conv2` и найдите спектр $\lambda$.

- **Попытка наивной оценки (МНК):** Попробуйте построить линейную регрессию ($\ln \rho(\lambda)$ против $\ln \lambda$) по точкам стандартной гистограммы.

  **Предупреждение:** Прямой МНК на линейных бинах гистограммы выдаст несостоятельную оценку $\alpha$, которая будет непредсказуемо скакать при изменении количества бинов (`bins`). **Подумайте:** Почему линейный шаг бинов делает оценку в хвосте непригодной, что происходит с мерой при логарифмических бинах и почему для степенных хвостов классический МНК статистически не применим?

- **Метод максимального правдоподобия (MLE / Оценщик Хилла):** Реализуйте (или примените из библиотеки `powerlaw`) состоятельный оценщик Хилла:

$$\alpha = 1 + N_{tail} \left[ \sum_{i=1}^{N_{tail}} \ln \frac{\lambda_i}{\lambda_{min}} \right]^{-1}, \quad \text{для } \lambda_i \geq \lambda_{min}$$

  где порог отсечения шума $\lambda_{min}$ подбирается минимизацией статистики Колмогорова–Смирнова $D_{KS}$ между эмпирическим хвостом и теоретическим распределением $P(\lambda) = 1 - (\lambda/\lambda_{min})^{-(\alpha-1)}$.

- **Визуализация:** Постройте эмпирическую функцию выживания (CCDF, $P(X \geq \lambda)$) в log-log масштабе, отобразите теоретическую аппроксимацию MLE и вертикальной линией отметьте границу шума $\lambda_{min}$.

**3. Диагностика патологий сети (Слепой тест)** Искусственно сформируйте тестовый набор из 4 слоев: 1. `layer1.0.conv1` — **Рандомизированный:** перезапишите веса случайными значениями $\mathcal{N}(0, \sigma^2)$, симулируя необученный/замороженный слой. 2. `layer2.0.conv1` — **Штатный:** оставьте веса исходной предобученной сети. 3. `layer3.0.conv1` — **Коллапсировавший:** примените SVD-разложение $W = U\Sigma V^T$, занулите все сингулярные числа, кроме первых двух, и восстановите матрицу весов. 4. `fc` — **Выходной:** исходный полносвязный слой классификатора.

Для каждого из четырех слоев: * Постройте график спектральной плотности. * Рассчитайте эффективный ранг (Stable Rank): $\text{srank}(W) = \frac{\|W\|_F^2}{\|W\|_2^2} = \frac{\sum \lambda_i}{\lambda_{max}}$. * Оцените показатель $\alpha$.

**Предупреждения к анализу крайних случаев:** На случайном слое (`layer1.0.conv1`) алгоритм `powerlaw` все равно вернет число. Подумайте, как с помощью формулы границы Марченко–Пастура $\lambda_+ = \sigma^2(1 + \sqrt{\gamma})^2$ строго доказать, что степенного хвоста у данного слоя на самом деле нет.

- **Итоговый вывод:** Соотнесите каждый слой с классификацией Мартина–Махони (Фазы 1–5). Укажите, какой слой находится в оптимальном режиме («Зона Златовласки»), какой слой выродился (коллапс ранга), а какой остался чистым белым шумом.